



# Feature Extraction of Images

## MNIST Veri Seti ile Dokusal Özellik Çıkarma ve Sınıflandırma

Bu çalışmada MNIST veri seti kullanılarak el yazısı rakam tanıma probleminin dokusal özellik çıkarma yöntemleriyle çözümüne odaklanmaktadır. Beş farklı makine öğrenimi sınıflandırıcısı test edilmiş ve bu yöntemlerin sınıflandırma performansına olan etkisi incelenmiştir. Çalışmada, GLCM, LBP, LBGLCM ve GLRLM gibi dokusal özellik çıkarma yöntemleri kullanılmıştır.

# El Yazısı Rakam Tanıma Problemi

## Giriş

Görsel verilerden anlamlı bilgi çıkarma, örüntü tanıma ve bilgisayar görme alanlarının temel hedeflerindendir.

El yazısı karakter tanıma (Optical Character Recognition - OCR), görüntü tabanlı bilgilerin metin formuna dönüştürülmesinde kullanılan köklü ve yaygın bir yaklaşımdır. Bu çalışmada, OCR yöntemleri el yazısı rakam tanıma problemi özelinde ele alınmıştır.

## Zorluklar

El yazısı karakter tanıma probleminin zorlukları şunlardır:

- **Yazım Stili Çeşitliliği:** Her bireyin yazım tarzı farklıdır.
- **Gürültü ve Bozulmalar:** Görüntüler bulanık olabilir veya düşük çözünürlükte olabilir.
- **Sınıflar Arası Benzerlik:** "2" ve "3" gibi rakamlar arasında ayırım yapmak zordur.
- **Aydınlatma ve Kalem Kalınlığı Değişkenliği:** Dokusal çeşitliliği artırır ve sınıflandırmayı zorlaştırır.

# Kullanılan Veri Seti: MNIST

MNIST veri seti, el yazısı rakam tanıma için standart bir benchmarktır:

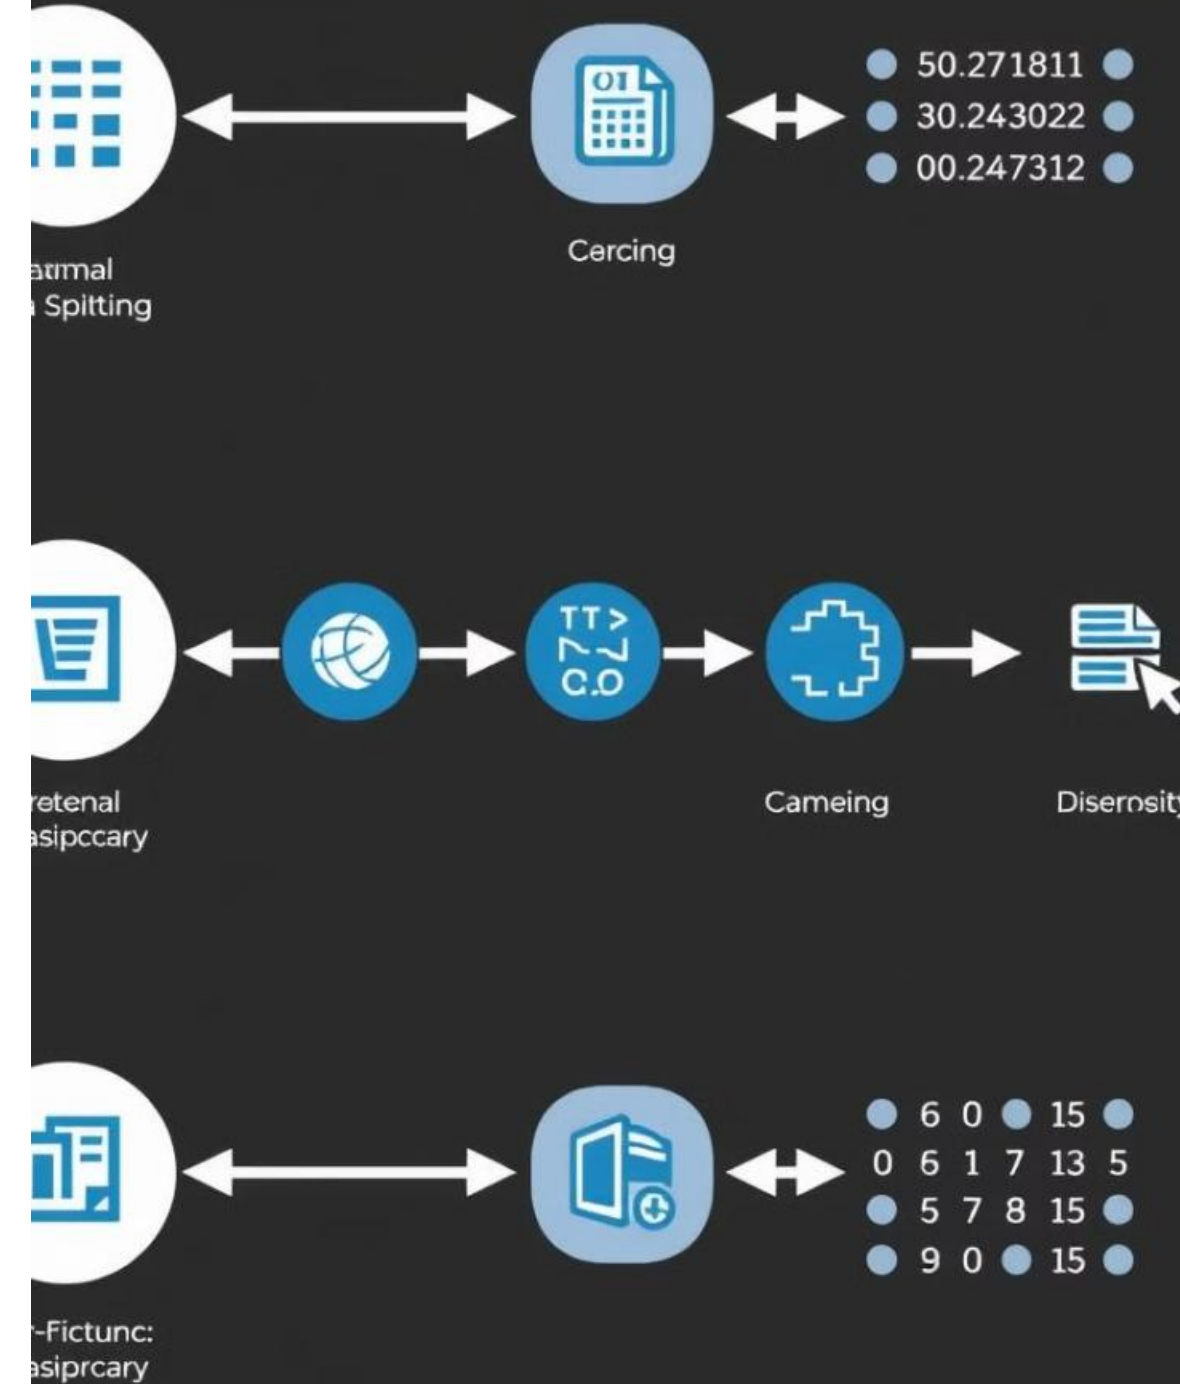
Sınıflar	Görüntü Boyutu	Eğitim Verisi	Test Verisi
0-9 arasında toplam 10 sınıf.	28x28 piksel.	60.000 örnek.	10.000 örnek.

Veri CSV formatında temin edilmiştir. Piksel verileri 0-255 arasında gri tonlama değerlerindedir.



# Deneyisel Kurulum

- 1 Eğitim Verisi Ayrımı  
Eğitim verisinden %20 validation seti olarak ayrılmıştır.
- 2 Özellik Standardizasyonu  
Özellikler ortalama 0, standart sapma 1 olacak şekilde normalize edilmiştir.
- 3 Sınıflandırıcılar  
Destek Vektör Makineleri (SVM), Rastgele Orman, k-En Yakın Komşu, Lojistik Regresyon, Karar Ağacı.
- 3 Dokusal Özellik Çıkarma Yöntemleri  
GLCM, LBP, LBGLCM ve GLRLM gibi dokusal özellik çıkarma yöntemleri kullanılmıştır



# Kullanılan Sınıflandırıcılar

Destek Vektör  
Makineleri (SVM)

`SVC(probability=True,  
random_state=42)`  
kullanılmıştır.

Rastgele Ormanlar

`RandomForestClassifier  
(random_state=42)`  
kullanılmıştır.

Lojistik Regresyon

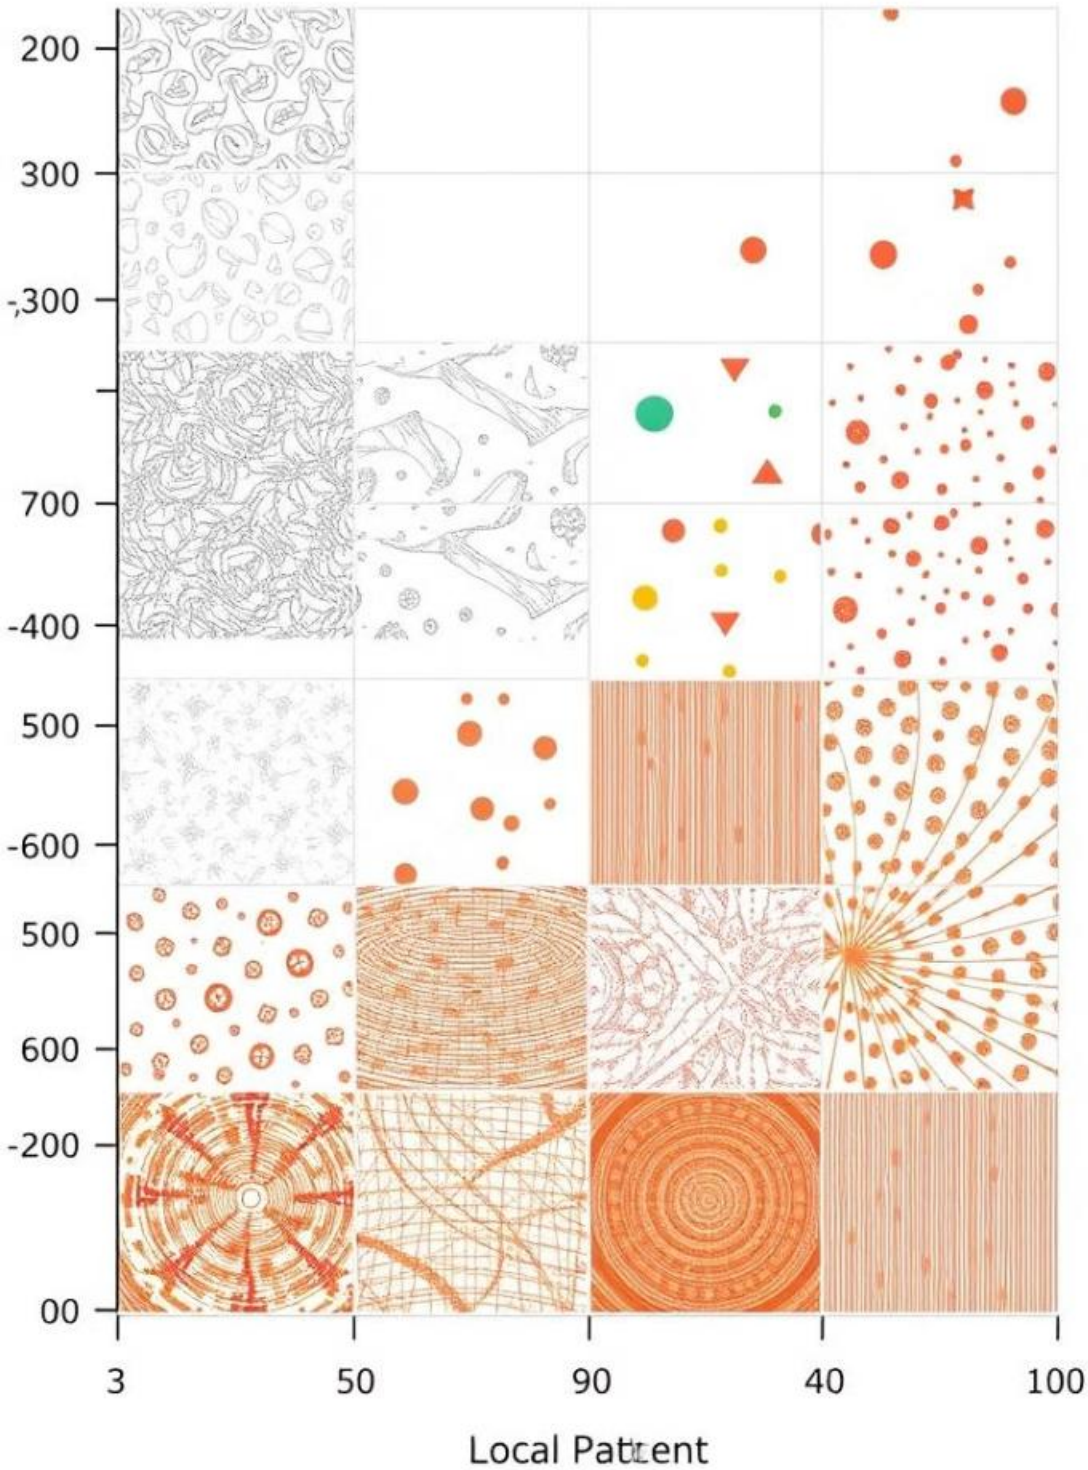
`LogisticRegression(rand  
om_state=42)`  
kullanılmıştır.

Karar Ağacı

`DecisionTreeClassifier(r  
andom_state=42)`  
kullanılmıştır.

k-En Yakın Komşu (K-NN)

# Dokusal Özellik Çıkarma Yöntemleri



1

## 1. Gray Level Co-occurrence Matrix (GLCM)

Piksel çiftlerinin birlikte görülme olasılığını analiz eder, kontrast, enerji, homojenlik, korelasyon gibi istatistikler çıkarır.

3

## 3. Local Binary Gray Level Co-occurrence Matrix (LBGLCM)

LBP ile elde edilen yerel desen bilgilerini GLCM ile birleştirir, hem yerel desen hem de gri seviye ortak dağılımlarını analiz eder.

2

## 2. Local Binary Pattern (LBP)

Her pikselin komşularına göre parlaklık ilişkisini ikili bir kodla ifade eder, kodların histogramını dokusal imza olarak kullanır.

4


## 4. Gray Level Run Length Matrix (GLRLM)

Belirli yönlerde aynı gri seviyeyi taşıyan piksel dizilerinin (run) istatistiklerini inceler, görüntünün tekrar eden yapısını ortaya koyar.

# Gray Level Co-occurrence Matrix (GLCM)

GLCM, bir görüntüdeki piksel çiftlerinin belirli bir uzaklık ve yöndeki gri seviye ilişkilerini temsil eder. GLCM'den çıkarılan temel istatistikler:

- Kontrast:** Gri seviye farklarının yoğunluğunu ölçer.
- Enerji:** Matris yoğunluğunu temsil eder.
- Homojenlik:** Pikseller arası gri seviye farklarının azlığını ölçer.
- Korelasyon:** Gri seviyeler arasındaki doğrusal ilişkiyi ifade eder.



## Local Binary Pattern (LBP)

LBP, her pikselin komşu piksellerine göre parlaklık ilişkisini ikili bir kodla temsil eder. Bu kodlar histogram halinde özetlenir.

**Örnek:** Bir pikselin değeri çevresindekilerden büyükse "1", küçükse "0" olarak kodlanır.

Histogram, bu kodların dağılımını gösterir.



Temel formülasyon şu şekildedir: Bir pikselin değeri  $I_c$  ve etrafındaki  $P$  adet komşu piksel  $I_p$  olsun (bu pikseller belirli bir yarıçap  $R$  ile örneklenir). LBP değeri:

$$LBP_{P,R}(x_c, y_c) = \sum_{p=0}^{P-1} s(I_p - I_c) 2^p$$



# Local Binary Gray Level Co-occurrence Matrix (LBGLCM)

LBGLCM, LBP çıktısını kullanarak GLCM hesaplama fikrine dayanır. İlk adımda LBP ile elde edilen yerel dokusal bilgi, görüntünün her pikseline bir “desen değeri” atar. Ardından, bu LBP ile elde edilen yeni “gri seviye uzayında” GLCM hesaplanır. Böylece, sadece orijinal gri seviyeler arasındaki ilişki değil, aynı zamanda yerel desenlerin birlikte bulunma istatistikleri de yakalanır.




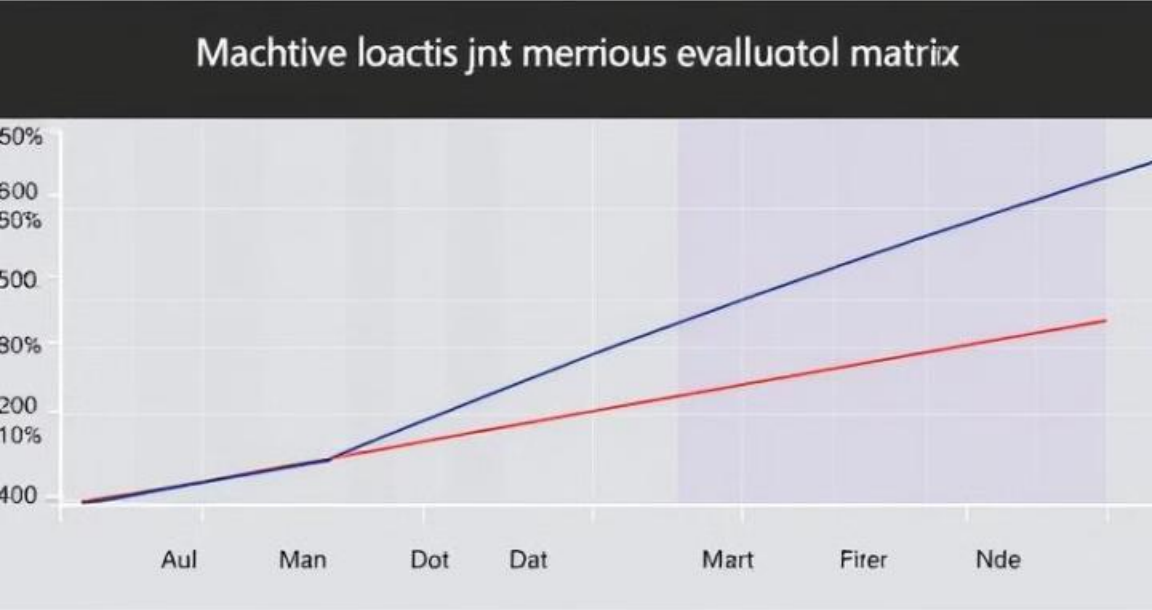
# Gray Level Run Length Matrix (GLRLM)

GLRLM, belirli bir yönde aynı gri seviyeye sahip ardışık piksel sayılarının (run) dağılımını ortaya koyar.

Bir “run”, aynı gri değere sahip bir dizi ardışık pikselden oluşur. GLRLM, her gri seviye değeri için run uzunluklarının frekansını kaydeder.

Bu matristen çeşitli istatistikler türetilebilir, ancak bu çalışmada GLRLM tam kapsamıyla değil, basit bir run analiziyle sınırlı kalınmıştır.





Glargh nacrisc

uracy	826	773	876		11%	10%	70%	74%
urats	876	627	875		83%	10%	88%	80%
ision	882	460	250		445	15%	40%	64%
carel	346	168	155		2.35	10%	40%	07%
anal	318	509	470		15%	13%	80%	40%
scars	868	855	158		22%	19%	50%	80%
auth	225	176	162		12%	15%	67%	40%
core	935	820	770		1.00	10%	40%	40%

# Değerlendirme Metrikleri



Doğruluk

Doğru sınıflandırılan örneklerin oranı.



Precision, Recall, F1-Skoru

Sınıf bazlı performansı detaylı inceler.



Karışıklık Matrisi


Hangi sınıfın hangi oranda başka bir sınıfa karıştırıldığını gösterir.



ROC Eğrisi ve AUC

Sınıflandırma eşiği değiştikçe hassasiyet (TPR) ile FPR arasındaki ilişkiyi gösterir. AUC değeri, genel ayırtırma gücünü ölçer.

# Tüm Özelliklerin Birleştirilmesi





Sınıf	Precision	Recall	F1-Skor
0	0.93	0.94	0.93
1	0.98	0.98	0.98
2	0.56	0.50	0.53
3	0.64	0.72	0.68
4	0.81	0.87	0.84
5	0.61	0.60	0.60
6	0.68	0.63	0.65
7	0.79	0.79	0.79
8	0.82	0.81	0.82
9	0.68	0.67	0.68

# Test Seti Sonuçları



## Genel Doğruluk

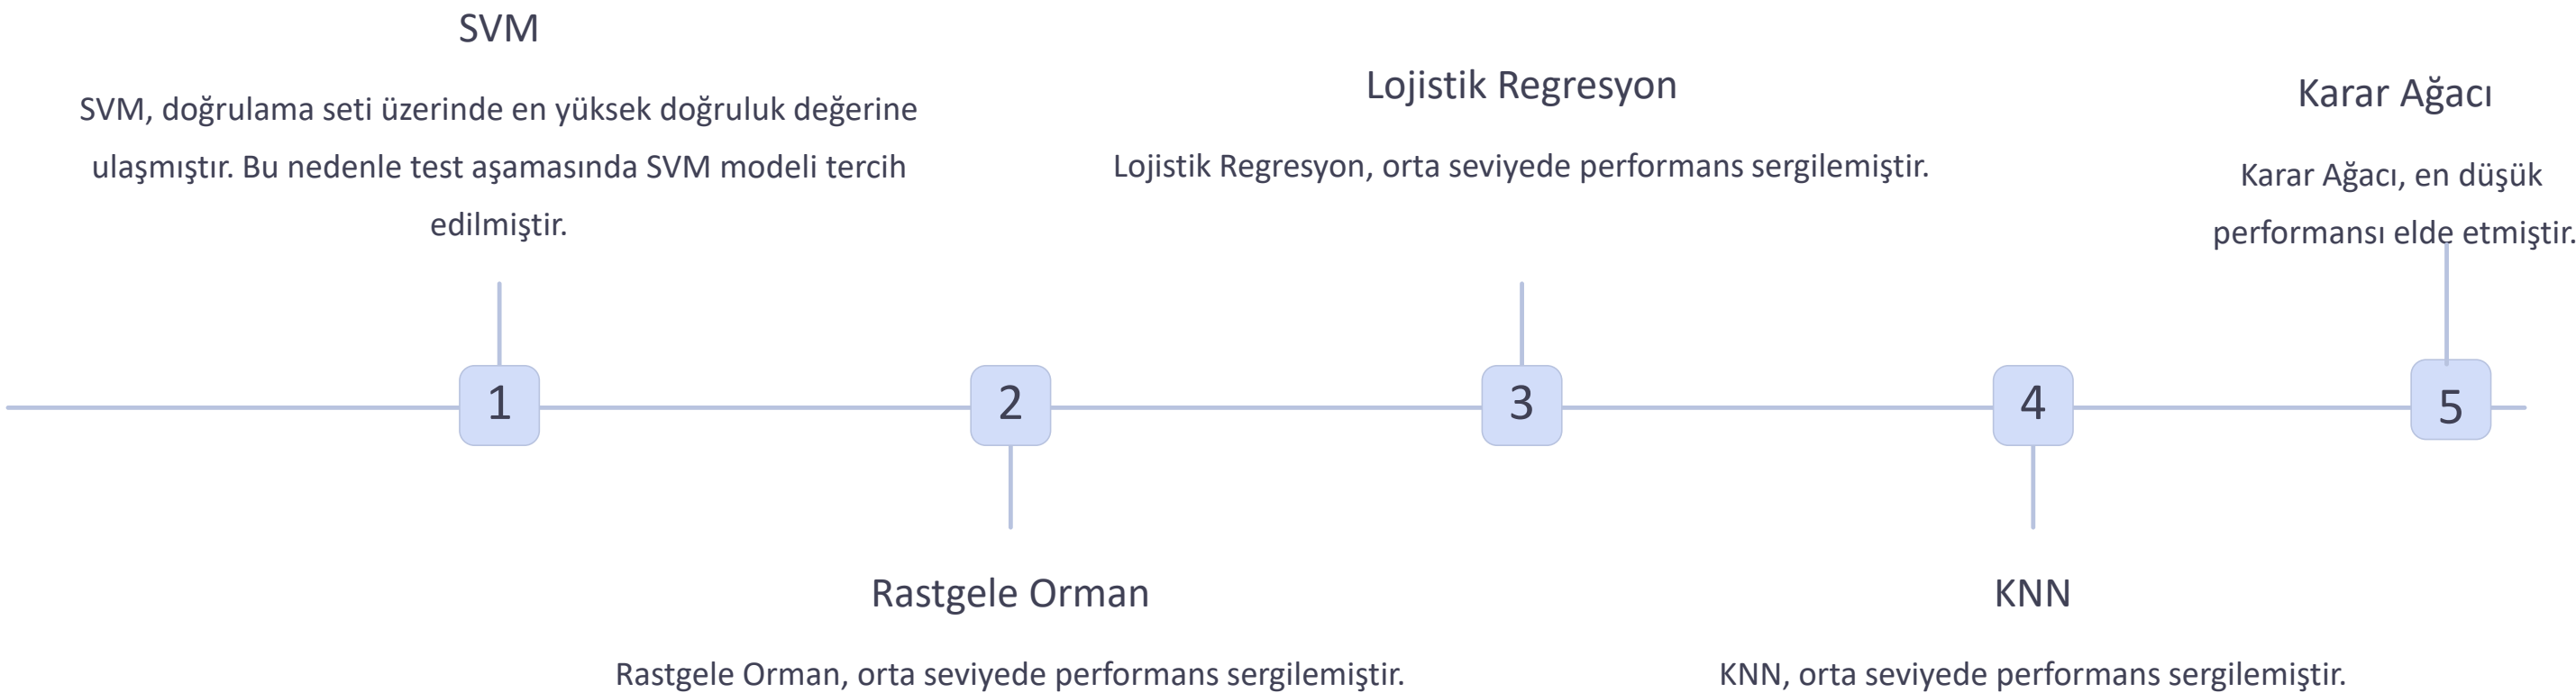
Test setinde %76 civarı doğruluk elde edilmiştir.

## Sınıf Bazlı Metrikler


Bazı rakamlar diğerlerine göre daha kolay tanınmıştır (örneğin “0” ve “1” oldukça başarılıyken “2” sınıfında başarı daha düşüktür). Bu, dokusal özellik setinin bazı rakamları ayırt etmekte daha başarılı olduğunu, bazılarında ise yetersiz kaldığını göstermektedir.

# Model Performans Karşılaştırması

Model	Doğruluk (Validation)
Random Forest	~0.6817
SVM	~0.7336
KNN	~0.6273
Logistic Regression	~0.6778
Decision Tree	~0.5391



# Karışıklık Matrisi Analizi (SVM)



## Yüksek Doğruluk

"0" ve "1" sınıfları için yüksek doğru tanıma sayısı.

## Düşük Doğruluk

"2" ve "3" sınıfları için daha fazla hata.

# Görselleştirmeler ve Yorumlar



## Model Doğruluk

SVM en iyi performansı göstermiştir.




## Karışıklık Matrisi

Özellikle "0" ve "1" sınıflarında yüksek doğruluk, "2" ve "3" sınıflarında daha fazla hata gözlenmiştir.



## ROC Eğrileri

SVM modeli genel ayırıştırma gücünde üstünlük sağlamıştır.





# Sonuçlar ve Tartışma



Bu çalışmada, dokusal özellik çıkarma yöntemleri ve geleneksel sınıflandırıcılar kullanılarak MNIST veri setinde el yazısı rakam tanıma gerçekleştirilmiştir. Gelişmiş derin öğrenme yöntemlerine kıyasla doğruluk oranı daha düşük olsa da, dokusal özelliklerin sınıflandırma performansına katkısı başarılı bir şekilde analiz edilmiştir.



# Teşekkürler

Bu sunumu dinlediğiniz için teşekkür ederim. Umarım faydalı bulmuşsunuzdur.  
Herhangi bir sorunuz varsa lütfen çekinmeden sorun.