

Zaman Serilerinde Talep Tahmini (Demand Prediction In Time Series)

Büşra YÜKSEL

Selçuk Üniversitesi, Bilgisayar Mühendisliği, busraa.yksel@gmail.com

Özet

Talep tahmini, gelecek vadede tüketicilerin bir hizmet veya ürüne olan talebinin öngörülmesi işlemidir. Talep tahmini, sektör fark etmeksizin tedarikçi ve üretici firmalar için depo planlanmasında büyük bir öneme sahiptir. Ayrıca talep tahmin işleminin en az hata ile yapılması üretici firmaların bu bağlamda üretilen ürünün malzeme temininden maliyet tasarrufuna, iş akış sürecinde optimizasyona ve verimliliğe; tedarikçi firmaların ise stok yönetiminin doğru yapılması ile buna bağlı olarak müşteri memnuniyetine ve rekabet üstünlüğüne kadar daha sayılabilecek birçok fayda sağlamaktadır. Talebin gerçek değerden fazla tahmin edilmesi stok fazlalığından kaynaklı mali zarara, az tahmin edilmesi ile müşteri taleplerini karşılayamamaktan kaynaklı müşteri kayıpları gibi istenmeyen sonuçlar doğurabilir. Talebin doğru tahmini ile bu sonuçların önüne geçilebileceği gibi, stok fazlalığından kaynaklı atık ve israfın önüne geçilerek çevreye de büyük katkı sağlanmasına kadar dolaylı olarak birçok katkısının bulunması talep tahmin konusunun önemini vurgular niteliktedir. Talep tahmin işlemi için birçok yöntemin bulunması hangi yöntemin daha uygun olacağı sorusunu akıllara getirmektedir. Daha önceleri uzman kişilerin öngörülleri ile yapılan sezgiselliğe dayalı talep tahmin yöntemleri kullanılmaktaydı. Günümüz teknolojisinde yapay zekanın hızla gelişmesiyle birlikte nitel yöntemler üzerinden yapılan talep tahmin işlemleri yerini nicel yöntemlere bırakmaya başlamıştır. Bu makalede nicel talep tahmin yöntemleri uygulanmıştır. Proje CRISP-DM metodolojisi ile uygulanmış, perakende sektöründeki bir firmanın satış verilerini içeren “Retail Data Set” veri kümesi ile zaman serileri oluşturularak, zaman serisi analizleri ve tahmin işlemleri gerçekleştirilmiştir. Proje dahilinde tek değişkenli zaman serileri üzerinden ARIMA, SARIMA; çok değişkenli zaman serileri üzerinden SARIMAX, LSTM, LightGBM, CatBoost, XGBoost ve MULTIPLE LINEAR REGRESSION modelleri uygulanmıştır. ARIMA, SARIMA ve SARIMAX modellerine otomatik ARIMA ile; LightGBM, CatBoost, XGBoost modellerine Grid Search ile parametre ayarı yapılmış ve model değerlendirmeleri MAPE, MSE ve RMSE ile yapılarak en iyi performansı CatBoost modelinin sağladığı tespit edilmiştir. CatBoost modeli ile veri kümesindeki son tarihten sonraki 7 günlük bağımsız değişkenler ve bu değişken değerleri ile talep tahmin edilmiştir. Son olarak projenin nasıl geliştirebileceği, ne gibi özelliklerin eklenebileceği ve no-code (kodlamasız) mantığının olduğu sistemler (örneğin Kolay.ai) ile talep tahmin işlemleri incelenmiştir.

Anahtar kelimeler: Talep Tahmini, CRISP-DM, Zaman Serileri, Grid Search, Kolay.ai

Summary

Demand forecasting is the process of predicting the demand of consumers for a service or product in the future. Demand forecasting is of great importance in warehouse planning for suppliers and manufacturing companies regardless of the sector. In addition, performing the demand forecasting process with minimal errors provides manufacturers with many more benefits ranging from material procurement of the product to be produced in this context, cost savings, optimization and efficiency in the workflow process; supplier companies, due to proper inventory management, customer satisfaction and competitive advantage. Overestimating the demand from the actual value may lead to undesirable consequences such as financial losses caused by inventory excess, customer losses caused by failure to meet customer demands with underestimation. As well as these results can be prevented by accurate forecasting of demand, the fact that many indirect contributions can be made from excess inventory to preventing waste and waste and making a major contribution to the environment emphasizes the importance of demand forecasting. The fact that there are many methods for demand forecasting brings to mind the question of which method will be more suitable. Previously, demand forecasting methods based on heuristics made with the predictions of experts were used. With the rapid development of artificial intelligence in today's technology, demand forecasting operations performed through qualitative methods have started to be replaced by quantitative methods. Quantitative demand forecasting methods have been applied in this article. The project was implemented using the CRISP-DM methodology, time series were created with the "Retail Data Set" dataset containing the sales data of a company in the retail sector, time series analysis and forecasting operations were performed. ARIMA, SARIMA, SARIMA, SARIMAX, LSTM, LightGBM, CatBoost, XGBoost and MULTIPLE LINEAR REGRESSION models were applied over univariate time series within the project; SARIMAX, LSTM, LightGBM, XGBoost and MULTIPLE LINEAR REGRESSION models over multivariate time series. ARIMA, SARIMA and SARIMAX models were automatically adjusted with ARIMA; LightGBM, CatBoost, XGBoost models were adjusted with Grid Search and model evaluations were made with MAPE, MSE and RMSE and it was determined that the CatBoost model provides the best performance. With the CatBoost model, the demand was estimated with the independent variables for 7 days after the deadline in the dataset and the values of these variables. Finally, how the project can be improved, what features can be added, and systems with no-code logic (for example Kolay.ai) the importance of the demand forecasting process has been examined.

Keywords: Demand Forecasting (Prediction), CRISP-DM, Time Series, Grid Search, Kolay.ai

1. GİRİŞ

Ham, işlenmemiş bilgi olarak adlandırılan veri kavramı günümüz dünyasında önemli bir yer edinmiş durumdadır. Bu veri kavramı tek başına bir anlam ifade etmeyen, gereksiz bir yer tutucudur gibi düşünülebilir. Ancak bu veriler bir amaca ulaşmak için kaynak olarak kullanıldığı takdirde değerli hale gelmektedir. Bu kapsamda işlenmiş veriden elde edilen anlamlı bilgileri kullanarak geçmişte yaşanmış bir takım olayların gizli kalmış yönlerinin ortaya çıkarılması, bazı öngörülerde bulunmakla beraber stratejiler geliştirmek, bazı oluşabilecek istenmeyen durumların önüne geçmek için önlemler almak gibi kazançlar sağlanır. Bu durumlar için eğitim, sağlık, alışveriş, bankacılık, sosyal platformlar vb. birçok alanda geçmiş verilerin depolanması konusu ortaya çıkmıştır. Bu bağlamda veri tabanları, bulut sistemler gibi depolama sistemlerinde veriler bilgiye dönüştürülerek analizler ve çıkarımlar yapılarak geleceğe dair fikirler edinilmesi için saklanır. Konu verilerin kullanıldığı bu alanlardan açılmışken alışveriş alanında özellikle perakende sektöründeki firmalar için geçmiş satış verileri büyük bir önem arz etmektedir. Geçmiş satış verileri ışığında gelecek ve süreç planlama işlemleri için satış verileri saklanmaktadır. Özellikle veriler gelecek satışları yani talep tahmini yapmak için bir maden niteliğindedir.

Talep, müşteri yani diğer bir deyişle tüketicilerin ürün ya da hizmeti belirli bir fiyatlayken aldıkları miktara denir. Talep tahmini ise üretilen veya tedarik edilecek ürün ve hizmetlerin müşteriler tarafından hangi değerde talep edileceğinin öngöründe bulunulması işlemini ifade eder. Talep tahmini sonucunda oluşan talep değerleri firmalar için personel temininde, pazarlama stratejilerinin geliştirilmesinde, kampanya oluşturulmasında, planlama gibi birçok işlem ve süreçte kullanılmaktadır [1]. Bu yüzden gelecekte belirli bir dönemde ürünlerin ne kadar talep edileceğinin öngörülmesi tedarikçi ve üretici firmalar için önemli bir yere sahiptir.

Talep tahmini yapmak için birçok yöntem mevcuttur. Ancak bu yöntemlerin hiçbiri kesin sonuç vermemektedir [2]. Çünkü talebi etkileyen birçok faktör bulunmaktadır. Örneğin talep tahminin yapıldığı dönemde piyasa durumu, mevsimsel etkiler, sosyal durumlar gibi birçok sebep talebi doğrudan veya dolaylı yoldan etkiler, bu da talebin beklenen değerden eksik ya da fazla olmasına sebep olur. Önemli olan tahmin edilen değerle gerçek satışlar arasındaki farkı en düşük seviyeye getirmeye çalışmaktır.

Geçmişte yapılan talep tahmini çalışmaları incelendiğinde enerji, gıda, tekstil, otomobil, temel ihtiyaçlar, turizm ve çeşitli hizmetlerin talebi gibi perakende sektörlerindeki ürün ve hizmetler üzerine yapılan bir çok proje bulunduğu gözlemlenmiştir [3]. Faaliyet gösteren ticaret firmaları, müşteri taleplerini daha hızlı karşılamak ve müşterilerine sorunsuz bir alışveriş tecrübesi yaşatmak için tedarikçi ve depo hizmet ağlarını etkin bir şekilde

yönetmesi gerekir. Depo kaynağına sahip ticaret firmaları, hem satıcı hemde tedarikçi rolüne sahiptir [4]. Bu durum da hemen hemen satıcı, tedarikçi konumundaki her firma için talep tahminin önemini vurgular niteliktedir. Talebin tahmin edilmemesi firmalar için istenmeyen birçok duruma sebebiyet verebilir. Örneğin stok yetersizliğinden kaynaklı satışlarda düşüş, müşteri kayıpları, stok fazlalığının beraberinde gertirdiği mali zarar, ayrıca bu fazlalıktan kaynaklı atıkların oluşmasıyla israf durumu ve çevre zararı gibi birçok istenmeyen durumlar zinciri oluşturmaktadır.

Bir tahmin projesinin ilk aşamalarında, neyin tahmin edilmesi gerektiğine dair kararlar alınması gerekir [5]. Tedarikçi komundaki bir firma ise hangi ürünlerin talep tahmininin yapılacağı belirlenmelidir. Satışı duran, az satışı olan veya satışı yeni başlayan ürünlerin talebinin tahminini yapmak hem vakit kaybı hem de gereksiz bir işlem olacak ve yanlış kararlar alınmasına sebebiyet verecektir. Bu yüzden ürünlerin belirlenmesi talep tahmini için önemli bir noktadır.

Talep tahmin işlemi için yöntemler uzmanlara dayalı nitel ve geçmiş veriler üzerinden hesaplamalara dayalı nicel yöntemlerden oluşmaktadır. Uzman kişi veya kişilerin tecrübe ve sezgiselerine dayalı nitel (kalitatif) tahmin yöntemlerini, günümüz teknolojisinde yapay zekanın yükselişi ile birlikte nicel diğer bir ismiyle kantitatif talep tahmin yöntemleri almaya başlamıştır. Literatürdeki talep tahmin çalışmaları çok eskiye dayanmakta ve günümüze kadar birçok nicel yöntemin uygulandığını göstermektedir. Perakende sektöründe ise çeşitli talep, satış tahminleme çalışmaları bulunmaktadır. Bu çalışmaların yapay sinir ağı modelleri üzerine yoğunlaştığı ve diğer yöntemlerle kıyaslanarak iyi performans sağladığının vurgusu yapılmıştır. Örnek olması açısından Tablo 1’ de farklı alanlardaki talep tahmin çalışmalarındaki incelenen bazı modellerin performans metrikleri verilmiştir.

Tablo 1. Bazı Projelerde Kullanılan Modellerin MAPE ve RMSE Değerleri

YAZAR	AMAÇ	YÖNTEM	MAPE	RMSE
<i>Tuğba SARI Bünyamin Salih GÜL (2021)</i>	<i>İlaç tahmini</i>	1. ARIMA 2. Holt-Winters 3. Bütünleşik YSA Modeli (ARIMA-Holt-Winters)	3,056 2,987 2,664	2574,229 2618,797 -
<i>Ahmet KARA (2019)</i>	<i>Global Güneş Işınımı Zaman Serileri Tahmini</i>	<i>LSTM</i>	<i>5.51</i>	<i>20.34</i>
<i>Radharani Panigrahi Nita R. Patne Sumanth Pemmada Ashwini D. Manchalwar (2022)</i>	<i>Saatlik Toplam Elektrik Talebi Tahmini</i>	1. Autumn CatBoost 2. Winter CatBoost 3. Spring CatBoost 4. Summer CatBoost	4.28 5.86 5.66 3.73	65.05 92.24 68.01 62.83
<i>Galip Altunay (2010)</i>	<i>Aylık Elektrik Talebi</i>	1. SARIMA (0,1,1) (1,1,1) 2. SARIMA (1,1,0) (2,0,1)	1.86 2.31	-
<i>Fatma Demircan Keskin Haluk Soyuer (2022)</i>	<i>Çimento Firmasında Talep Tahminleme</i>	1. SSM 2. LSTM	18,784 12, 278	13489,163 8938,473
<i>Muhammed Resul AYDIN Osman YAZICIOĞLU (2019)</i>	<i>Perakende Sektöründe Talep Tahmini</i>	1. Dana eti: YSA - ARIMA 2. Kuzu Eti: YSA - ARIMA 3. Tavuk Eti: YSA - ARIMA	YSA:4.0819 ARIMA:15.7521 YSA:2.539 ARIMA: 29.280 YSA: 0.8231 ARIMA:10.3951	-

Örneğin Sevgi (2012), tez çalışmasında bir hazır giyim perakende sektöründeki bir firmanın verileri ile zaman serileri oluşturularak talep tahmini ARIMA (1,1,1) ve yapay sinir ağlarından olan NARX modelini uygulamış orta ve uzun vadeli tahminler için NARX modelinin hata oranının az olduğunu gözlemlemiştir [6].

Başka bir çalışma Veiga ve ekip arkadaşları (2016), gıda perakende segmentinde üç grup bozulabilir gıda ürününün satışlarına ARIMA, Holt Winter, WNN (Dalgacık Sinir Ağları) ve Takagi modellerini uygulayarak karşılaştırmalarını yaptılar ve en iyi modelin tüm gruplarda WNN olduğu sonucuna ulaştılar [7].

Güven (2020), perakende hazır giyim endüstrisindeki ürün çeşitliliğini dikkate alarak satış talep tahminlerini yapay sinir ağları (ANN), rastgele ormanlar (RF) ve destek vektör makineleri (SVM) modelleri ile yapmıştır. Sonuçlara göre 14 veri setinin 8'inde YSA renk detaysız modeller diğer modellere göre daha iyi sonuçlar vermiştir. ANN renksiz verilerde 14 modelden 11'inde daha başarılı iken, SVM 13 modelde renk detaylı verilerde daha iyi sonuçlar verdiğini gözlemlemiştir. RF' nin renk detaylı ve renk detaysız verilerde benzer sonuçlar verdiğini sonucuna ulaşmıştır [8].

Aydın ve Yazıcıoğlu (2019) perakende sektöründe bir süpermarketin kasap reyonu için müşteri talep tahmini için zaman serisi yöntemlerinden ARIMA ile yapay sinir ağı modellerinin karşılaştırılmasını yapmışlar ve yapay sinir ağları modelinin daha iyi performans gösterdiğini gözlemlemiştir [9].


Ayrıca talep tahmini için kullanılan modellerin başka modellerle harmanlanarak yeni hibrit tahmin yöntemleri de uygulanmaktadır. Örneğin Thomas ve diğer ekip üyeleri (2008) yılındaki özel konut talep tahminindeki çalışmalarında genetik algoritma ve doğrusal regresyon modeli, ayrıca bu iki modelin birleşiminden oluşan bir hibrit modelde geliştirip uygulamışlardır. Hibrit modelin genetik algoritma ve doğrusal regresyondan daha iyi performans sağladığını göstermişlerdir [10].

Bahsedildiği üzere yapılan taramalar sonucunda talep tahmininde kullanılan yöntem ve modeller listesi uzayıp gitmektedir. Bu projede nicel tahmin yöntemleri zaman serileri üzerinden uygulanacaktır. Proje dahilinde perakende sektöründeki bir firmanın satış verileri incelenmiş az önce bahsedilen talep tahmini için ilk aşamalarda önemli olan talep tahmini yapılacak ürünlerin belirlenmesi yapılmış. Veri setinde detaylı bir analiz ile bazı çıkarımlar yapılmış. Talep tahminine dahil edilecek ürünlerden veri sayısı en çok bulunan ürün yani en çok satılan seçilerek bu ürün üzerinden zaman serileri oluşturularak en iyi model seçilir. Böylece her bir ürün üzerinden zaman serisi oluşturularak tüm modelleri denemekle vakit kaybı olmayacaktır. En iyi modelin belirlenmesi ile her bir ürün için zaman serisi oluşturularak veri setindeki son tarihten sonraki 7 gün için talep tahmini yapılmıştır. Bu sayede firmanın stoklarını tahminler aracılığıyla güncel tutulabilmesi amaçlanmıştır. Böylelikle perakende sektöründeki bir firmanın ürünlerinin hem çok değişkenli hem de tek değişkenli zaman serileri ile talep tahmini yapılmıştır.

2. METODOLOJİ

KDD (Knowledge and Data Discovery), SEMMA (Sample, Explore, Modify, Model, Evaluate) ve CRISP-DM (Cross-Industry Standard Process for Data Mining) isimli popüler 3 adet süreç modeli bulunmaktadır. Bu metodolojiler aslında uygulama adımları incelendiğinde birbirlerine çok benzeyen yöntemlerdir. Ancak KDD ve CRISP-DM daha yaygın tercih edilmektedir. Özellikle CRISP-DM popüleritesi daha da artmış bir yöntemdir [11]. Bu metodolojiler ile daha verimli ve sistematik bir şekilde proje uygulanabilir. Projenin kapsamı incelendiğinde, proje gereksinimlerini aşama aşama uygulayarak hedefe ulaşmak için veri bilimi, veri madenciliği gibi alanlardaki çalışmalar için tercih edilen CRISP-DM metodolojisi kullanılmıştır.

CRISP-DM metodolojisi, Daimler Chrysler AG, SPSS, NCR ve OHRA gibi lider veri madenciliği kullanıcıları ve tedarikçilerinden oluşan bir ekip tarafından geliştirilmiş ve dünyanın en büyük veri madenciliği çözümlerinin kullandığı altı adımdan oluşmuş bir süreçtir [12].



Şekil 1: CRISP-DM Metodolojisi

Şekil 1’ de görüldüğü üzere CRISP-DM, temelinde verinin bulunduğu 6 adımdan oluşan birbirini takip eden adımların oluşturduğu döngü şeklinde ilerleyen bir süreçtir.

2.1 İş Anlayışı – İş Anlama (Business Understanding)

Metodolojinin ilk safhası olan iş anlayışı; projenin hedeflerini ve ihtiyaçlarını anlamak, problemin tanımını kavramak ve iş ön planı oluşturmak gibi adımların uygulandığı kısımdır. Bu kısımda teorik olarak projenin neyi amaçladığı kavranmış, probleme uygun nasıl verilere-veri kümesine ihtiyaç olduğu belirlenmiş, nasıl ilerleneceği kestirilmiş olur. Kısacası uygulamaya geçmeden önceki araştırmaların yapıldığı, bilgilerin edinildiği, hangi veriler ile nasıl teknoloji ve metotların kullanılacağına belirlendiği teorik kısımdır. İş anlayışı sürecin en önemli aşamasıdır. Burada atlanılan, anlaşılmayan kısımlar ileride sorun teşkil edebileceği için tekrar bu aşamaya dönerek yeniden projeye başlanmasına sebebiyet verebilir. Bu aşama ayrıca metodolojinin bir sonraki safhası olan veriyi anlama (data understanding) ile etkileşim içindedir.

2.2 Veriyi Anlama (Data Understanding)

İlk aşamada projenin amacı ve probleme uygun bir veri kümesinin neler içermesi, nasıl değişkenlere sahip olması gerektiği gibi ihtiyaçlar belirlenmişti. Metodolojinin ikinci safhası olan bu aşamada projeye uygun veri seti bazı kaynaklar üzerinden temin edilir. Örneğin; kaggle, data.world, Data.Gov, Google Dataset Search gibi platform ve arama motorları vb. Verilerin toplanmasının ardından verilerin kalitesi, eksiklikleri; veriye sorular sorularak, analizler yapılarak tespit edilir. Kısacası veri kümesinin bulunduğu, bulunan veri kümesi gerçekten de projenin ana hedefine uygun mu , bu veri kümesiyle ilerlenebilir mi, ne gibi düzeltmeler yapılmalı ? gibi sorulara cevap aranan kısımdır. Yanıtın olumsuz olması durumunda bir önceki aşamaya geçilerek bulgular tekrar gözden geçirilir.

2.3 Veriyi Hazırlama (Data Preprocessing)

Bir önceki safhada tespit edilen sorunlar, eksikliklerin çözüldüğü kısımdır. Bu aşama eksik-yanlış-gürültülü verilerin ele alındığı, bu eksik verilerle nasıl başa çıkılacağı (eksik veriler tahmin mi edilecek, doldurulacak mı, silinecek mi ?), gürültülü-yanlış verilerin düzeltilmesi, temizlenmesi; aykırı değerlerin tespiti ve incelenmesi, değişken tiplerindeki anormalliklerin tespiti ve istenilen formata getirilmesi gibi kısımları ele alır. Bu ve benzeri sorunların çözülmesi ile oluşan temiz, kaliteli verilerden bazı görselleştirme teknikleri ile anlamlı sonuçlar çıkarılır ve veri seti bir sonraki aşamaya hazır hale getirilmiş olur.

2.4 Modelleme (Modeling)

Veri setinin eğitim ve test olmak üzere iki alt veri kümelerine bölünüp bu veri kümelerini de kendi içlerinde bağımlı, bağımsız (hedef) değişkenlere ayırıp eğitim veri setindeki gözlem birimlerinin, değişkenlerin, metodolojinin ilk safhası olan iş anlayışı kısmında belirlenen algoritmalar (regresyon, makine öğrenmesi algoritmaları vb.) ve fonksiyonlara verilerek modellerin oluşturulup eğitildiği kısımdır. Eğitim veri setindeki verilerle modellenin eğitilmesi ile model üzerinden bağımsız (hedef) değişkenin tahmin işleminin gerçekleştirildiği kısımdır. Modelleme de oluşabilecek problemleri önlemek adına bir önceki aşama olan veriyi hazırlama kısmına dönülebilir.

2.5 Değerlendirme (Evaluation)

Bir önceki aşamada oluşturulan modellerin test edilmesi kısımdır. Gerçek değerlerden oluşan test veri setindeki değerler ile modelin tahmin ettiği değerlerin karşılaştırılarak bazı hesaplamaların yapıldığı aşamadır.

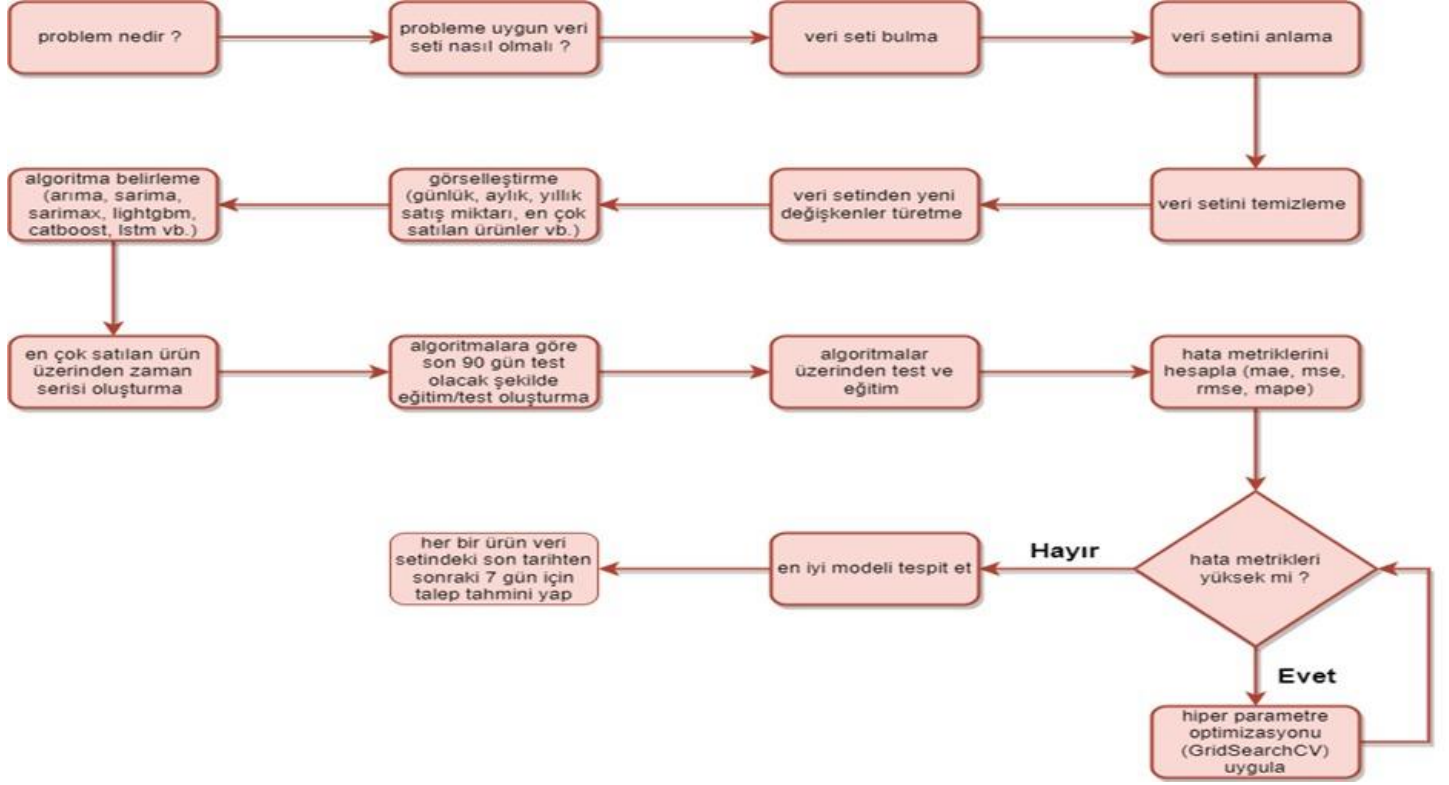
Bu hesaplamalar performans metrikleri olarak adlandırılır. Model performansını değerlendirmek için kullanılabilecek çeşitli metrikler vardır [13]. Bu metriklerle modellerin başarıları değerlendirilmiş ve en iyi model tespit edilmiş olur.

2.6 Canlıya Alma (Deployment)

CRISP-DM metodolojisinin son aşaması olan canlıya alma modelin doğruluğunun tespit edilmesinin ardından sistemin uygulanması, kullanıcıya sunulması aşamasıdır.

3. PROJENİN UYGULANMASI

Bu kısımda bir önceki kısımda bahsedilen süreç modeli olan CRISP-DM metodolojisi ile Şekil 2’deki bu projenin aşamaları ve kullanılan metotlar, modeller adım adım aktarılacaktır. Proje, Python programlama dili ile uygulanmıştır. Projede zaman serileri üzerinde modeller oluşturulup uygulanmıştır.



Şekil 2: Projenin Uygulanma Adımları

3.1 İş Anlayışı

Projeye başlamadan önce yani kodlama aşamasından önce projenin ana hedefi olan talep tahminini kavramak için geniş bir literatür araştırması işine girilmiştir. Bu bağlamda daha önce talep tahmini konusunda yapılan çalışmalar incelenmiş; makaleler, blog yazıları taranmıştır. Ayrıca kodlama kısmını da kavrayabilmek adına bazı platformlardaki talep tahmin projeleri incelenmiştir.

Araştırma boyunca zaman serileri üzerinde çalışmalar yapıldığı da gözlemlenmiştir. Her seri zaman serisi değildir, bir serinin zaman serisi olabilmesi için zamana bağlı bir durum olmalıdır [14]. Bu sebepten zaman serisi oluşturabilmek için nasıl bir veri kümesinin temin edilmesi gerektiği araştırılmıştır. Bu bağlamda talep tahmini için öncelikle ürün, satış ve tarih bilgisi gibi değişkenlerin bulunduğu bir veri setine ihtiyaç vardır.

Talep tahmin yöntemlerinin nitel ve nicel yöntemler olarak incelendiği öğrenilmiş bu yöntemlerden nitel yöntemler geçmiş verilerin yetersiz kalması sonucunda bu alanda tecrübeli bilirkişilerden bazı tahminlerde bulunması ile talep tahmini yapılması işlemidir. Yani işin bilimsellikten uzak olan yanındır bu sebepten kaynaklı tahmin işlemi genel olarak düşük performanslıdır. Bu yöntemin aksine nicel yöntemler ise geçmiş verilere dayalı ve bu veriler ışığında bazı matematiksel işlemler ile tahmin yapan taraftır [15]. Bu projenin amacında nicel yöntemlerin talep tahminindeki performans ve önemini açıklamaktır.

Proje dahilinde talep tahmininde kullanılan popüler modellerden olan ARIMA modellerinden: ARIMA, SARIMA, SARIMAX; yapay sinir ağlarından LSTM; makine öğrenmesi modellerinden LightGBM, XGBOOST, CATBOOST, MULTIPLE LINEAR REGRESSION uygulanmasına karar verilmiştir.

3.2 Veriyi Anlama

Bu projede bir önceki aşamada bahsedilen gereklilikleri sağladığı gerekçesiyle kaggle platformundaki “Retail Data Set” [16] isimli veri kümesi tercih edilmiştir.

Bu veri kümesinde 2019-01-01 tarihinden 2023-03-25 tarihine kadar totalde 29.103 adet gözlem birimi ve 8 adet değişken bulunmaktadır. Veri setindeki değişkenler, değişken tipleri ve her değişkenin ne anlama geldiği Tablo 2’ de açıklanmıştır.

Bu aşamada verilerde anormalliklerin olup olmadığını tespit etmek için veri kümesinde bazı filtreleme işlemleri yapılmıştır. Bu veri kümesinde boş değer bulunmamaktadır. ‘Unnamed: 0’ sütunu kolonu index bilgisini tuttuğu için talep tahmininde gereksiz bir sütun olduğu ve analiz işlemlerinde de bir fayda sağlamayacağı için projenin ilk aşamasında silinmesine karar verilmiştir. ‘Date’ sütunun object türünde olması problem teşkil edeceği için tarihler için ‘datetime’ tipine dönüştürülmelidir. Veri kümesindeki ‘Discount’ sütunundaki negatif değerler zam, pozitifler indirim anlamına gelmektedir. Ayrıca veri setinde ‘Quantity’ sütununun sıfır, ‘TotalSales’ sütunundaki değerlerinde sıfır olduğu tespit edilmiştir. Bu durumda bir satış işlemi gerçekleşmemiştir, bu veriler silinmelidir. Aynı şekilde ‘Quantity’ sütununun sıfırdan farklı, ‘TotalSales’ sütunundaki değerlerinde sıfır olduğu durumlar gözlemlenmiştir. Bu kayıtlar hediye veya ücretsiz ürünler olabilir. Bu durumlar satış işlemi sayılamayacağı için silinmelidir.

Tablo 2. Retail Data Set Özellikleri

DEĞİŞKEN	AÇIKLAMA	VERİ TİPİ
Unnamed: 0	İndex numarası.	int64
InvoiceID	İşlemin kimliği.	int64
Date	İşlem Tarihi	object
ProductID	Ürün kodu	int64
TotalSales	Satış fiyatı	float64
Discount	İndirim tutarı	float64
CustomerID	Müşteri kimliği	int64
Quantity	Ürün adeti	int64

Ayrıca proje kapsamında az satışı olan (100 kereden az satılan) veya yeni satışı başlayan ürünlerin veri sayısının yetersizliğinden kaynaklı tahmin kısmında yanlış tahmin sonuçları sağlayacağı; satışı duran ürünlerin ise tekrar satılmayacağı için bu ürünlerin tespitinin yapılıp veri setinden çıkarılması gerektiğine karar verilmiştir.


Veriyi daha iyi anlayabilmek için bazı görselleştirme işlemleri yapılabilmesi adına ve modelin daha iyi tahmin sonuçları vermesi için özellik mühendisliğine gidilerek ‘Date’, ‘Quantity’, ‘TotalSales’, ‘Discount’ sütunları üzerinden yeni değişkenler türetilmesine karar verilmiştir. Bu yeni türetilen özellikler ile veri setinin son hali Tablo 3’ te gösterilmiştir. Veri kümemiz 21 değişkenli hale gelmiştir. Görselleştirme işlemleri ‘matplotlib’ kütüphanesi aracılığı ile gerçekleştirilmiştir.

Tablo 3. Retail Data Set Son Özellikleri

DEĞİŞKEN	AÇIKLAMA	VERİ TİPİ
InvoiceID	İşlemin kimliği.	int64
Date	İşlem Tarihi	datetime64[ns]
ProductID	Ürün kodu	int64
TotalSales	Satış fiyatı	float64
Discount	İndirim tutarı	float64
CustomerID	Müşteri kimliği	int64
Quantity	Ürün adeti	int64
UnitPrice	Ürünün Birim Fiyatı (TotalSales / Quantity)	float64
DiscountPercentage	İndirim Yüzdesi	float64
HasDiscount	İndirim var / yok	int64
Day_of_Month	Ayın günü	int64


Year	Yıl	int64
Month	Ay	int64
Day_of_Week	Haftanın günü	int64
day_of_year	Yılın günü	int64
is_wknd	Hafta sonu mu ?	int64
is_saturday	Cumartesi mi ?	int64
Quarter	Çeyreklik	int64
Season	Mevsim	int64
is_month_start	Ayın başı mı ?	int32
is_month_end	Ayın sonu mu ?	int32

Şekil 3’ teki sonuca göre en çok satış Perşembe (3) günü yapılmakta, pazar günü (6) ise hiç satış yapılmamakta. Yani bu firma pazar günleri sipariş kabul etmemekte.




Şekil 3: Haftanın Günlerine Göre Toplam Satış Miktarı

Şekil 4’ te ise bir aylık toplam satış miktarları incelenmiş satışların ayın sonlarına doğru doğrusal bir şekilde arttığı gözlemlenmiştir.




Şekil 4: Aylık Toplam Satış Miktarı

Şekil 5’ te ise 2019’ un başından 2023 yılın mart ayına kadar aylık toplam satışlar çizdirilmiş, bu 5 seneye göre satışların genel olarak yıl içinde 6., 7. ve 8. aylarda yani yaz aylarında zirve yaptığı gözlemlenmiştir.



Şekil 5: Yıllara Göre Aylık Toplam Satış Miktarları

Şekil 6’ da ise satışı en yüksek 10 ürün gösterilmiştir. En çok satılan ürün olan 1830 numaralı ürün 4000 küsür adet satılmıştır.



Şekil 6: Satışı En Yüksek 10 Ürün

3.3 Veriyi Hazırlama

Bu aşama bir önceki aşama olan veriyi anlama ile tespit edilen eksiklikler ve anormalliklerin veri setinden çıkarılması işlemidir. İlk olarak veri setinde bir önceki aşamada bahsedilen ‘Quantity’ ve ‘TotalSales’ değişkenlerindeki hatalı veriler çıkarılmıştır.

100' den az satışa sahip ürünler, son 3 ay içinde satışı başlamış ürünler ve son 6 aydır satılmayan yani satışı duran ürünlerin çıkarılmasının ardından totalde 27 adet ürün kalmıştır.

Bu projede en çok satılan ürün seçilerek bu ürün üzerinden bir zaman serisi oluşturulur. Bu zaman serisi üzerinden modeller uygulanıp en iyi model seçilecektir. Bu ürün üzerinden 'Date' değişkeni kullanılarak hem çok değişkenli (bağımsız değişkenler) hem de tek değişkenli (bağımlı değişken-hedef değişken) zaman serileri oluşturulmuştur. Burada hem çok hem de tek değişkenli seriler oluşturulmasının nedeni ARIMA ve SARIMA modellerinin tek değişkenle çalışması diğer bahsedilen modellerin ise çok değişkenle çalışabilmesi ile ilgili dir. Çok değişkenli seriden 'InvoiceID', 'ProductID', 'CustomerID' sütunları talep tahmininde etkili olmayacağı düşünüldüğü için çıkarılmıştır. Son durumda elimizde tek değişkenli (hedef değişken 'Quantity') için train_data ve test_data; çok değişkenli de ise X_train, y_train, X_test ve y_test veri kümeleri var. Veri kümelerinin gözlem sayıları ise tek değişkenlide train_data 283, test_data 33; çok değişkenlide X_train ve y_train 286, X_test ve y_test için ise 33 adet gözlem birimi bulunmaktadır.

3.4 Modelleme

İlk aşama olan 3.1' deki iş anlayışı aşamasında yapılan kapsamlı araştırmalar sonucunda karar verilen modellerin uygulanması işlemidir. Modelleri uygulamadan önce zaman serisi üzerinden birtakım analizler yapılarak uygulanacak modeller için bazı çıkarımlar yapılması gerekmektedir. Daha önce 1830 numaralı en çok satan ürün üzerinden oluşturulan çok değişkenli ve tek değişkenli zaman serileri son 90 gün hariç eğitim, son 90 günlük veriler ise test olarak ayrılmıştır. Tek değişkenli zaman serisi üzerinden ARIMA ve SARIMA; çok değişkenli zaman serisi üzerinden SARIMAX, LSTM, XGBOOST, LightGBM, CATBOOST ve MULTIPLE LINEAR REGRESSION modelleri uygulanacaktır. ARIMA modellerinde otomatik ARIMA, daha önce Şekil 2' de gösterilen projenin aşamalarında belirtilen yüksek performans metrikleri sonuçlarından kaynaklı makine öğrenmesi modellerinde Grid Search ile parametre ayarı yapılmıştır.

3.4.1 ZAMAN SERİSİ ANALİZİ (Durağanlık)

Zaman serisi analizinde önemli bir husus serinin durağanlık kontrolünün yapılmasıdır. ARIMA modellerinin uygulanabilmesi için serinin durağan olması gerekmektedir.

Zaman serisinin durağan olmasından kasıt, serinin belirli bir eğilim göstermesi demektir. Zaman serisinin durağan olmadığı gözlemlenmişse durağan hale getirmek için durağan hale gelene kadar farkının alınması ile durağanlaştırılır. Böylece Otoregresif Bütünleşik Hareketli Ortalamalar yapısı oluşmuş olur [9].

Serinin durağan olup olmadığı zaman serisinin bileşenlerinin grafiklerini incelemek, dickey fuller testi uygulamak, ACF ve PACF grafiklerini inceleyerek anlaşılabilir. Bu sayılan yöntemlerin hepsi tek değişkenli zaman serisi üzerinden uygulanmıştır.


Zaman serilerinde bazı koşulların etkisi vardır. Buradaki koşullar yani zaman serisi bileşenleri olarak bahsedilen Trend (T), düzenli dalgalanmalar yani mevsimsellik ve düzensiz dalgalanmalar olarak isimlendirilen kesin sebebi bilinmeyen dalgalanmalardır [17].

Bu terimlerden T ile gösterilen trend bir değişkenin değerlerinin belirli bir zaman aralığında göstermiş olduğu artma veya azalma eğilimine denir. Genelde trend durumuna iklimsel olayların incelenmelerinde sıklıkla rastlanır. Burada gösterilen eğilimlerin bazen arttığı bazense yavaşladığı gözlemlerin yani trend sabit değildir [18].

Mevsimsel bileşen ise bir yıl boyunca veya dört çeyrek yılda bir oluşan kesin dönem dalgalanmaları olarak tanımlanır. Diğer bir bileşen olan düzensiz dalgalanma ise birçok farklı sebepten olabilecek örneğin iklimsel, ekonomik, sosyal vb. olaylardan kaynaklı hareketlerdir ve diğer bileşenlerin aksine durağandır [19]. Ayrıca düzensiz dalgalanmalar başka kaynaklarda artık, tortu gibi isimlendirmelerde alır.

Bu bahsedilen zaman serisi bileşenlerini incelemek için 1830 numaralı ürün üzerinden oluşturulan tek değişkenli zaman serisinde Python' ın 'statsmodels' isimli kütüphanesi uygulanır. Bu kütüphanenin STL sınıfından periyodu 1 senelik inceleme için 12 olarak belirlenerek bir model oluşturulur ve eğitilir. Bu eğitimden trend, seasonal ve resid değerleri ile zaman serisi bileşenleri alınır.

Şekil 7' de sırası ile trend, mevsimsellik ve düzensiz bileşen değerleri görülmektedir. Bu üç çizim değeri incelenicek olursa 12 aylık period değerinde yani bir senelik döngüde belirgin bir şekilde trend ve mevsimselliğin olmadığı ve serinin durağan olduğu sonucu görülmektedir. Bu çıkarımda bize ARIMA modelinin SARIMA modelinden daha iyi performans gösterebileceği ile ilgili bir ön bilgi vermektedir. Tabiki bu görseller bu konuda tecrübeli uzmanlar tarafından daha detaylı tetkik edilebilir.



Şekil 7: Zaman Serisi Bileşenleri (trend, mevsimsellik, düzensiz bileşen)

Zaman serilerinin durağan olup olmadığını anlamanın bir kaç yöntemi vardır. Bu yöntemlerde genellikle birim kök testleri uygulamaktır. Yaygın olarak Dickey-Fuller birim kök testi uygulanır. Bu test sonucuna göre birim kök varsa seri durağan değildir [20].

Bu test iki hipotez üzerine kurulmuştur:

- H_0 : Değişkenlere ait seriler durağan değildir.
- H_1 : Değişkenlere ait seriler durağandır.

Testten elde edilen test istatistiği, p değeri ve kritik değerler ile hangi hipotezin reddelip hangisinin kabul edileceğine karar verilir.


Olasılık değeri olan p değerinin %5 altında olması halinde H_0 hipotezi %5 anlamlılık düzeyinde reddedilir yani serinin durağan olmadığı anlaşılır. Ancak p değeri %5'ten daha yüksek olması halinde ise sıfır hipotezi reddedilmez yani seri durağan değildir sonucu ortaya çıkar [21]. Ayrıca test istatistiği sonucu %1 kritik değerinden düşükse de H_0 hipotezi reddedilir.

Bu test için yine Python'un 'statsmodels' kütüphanesinin 'adfuller' sınıfı üzerinden seriye dickey fuller testi uygulanır.

Çıkan sonuçlar:

- ADF-GLS Test İstatistiği: -17.10449594718599
- p-value: 0.000000
- Kritik Değerler:
 - 1%: -3.451
 - 5%: -2.871
 - 10%: -2.572

Buradan p değerinin %5 anlamlılık düzeyinin altında olmasından ve test istatistiği sonucunun %1 kritik değerinden düşük olmasından kaynaklı H_0 hipotezi reddedilir yani seri durağandır.



Şekil 8: Zaman Serisi ACF ve PACF Grafikleri

Durağanlaştırma işlemi için kullanılabilecek diğer yöntemler ise, otokorelasyon fonksiyonu (ACF) ve kısmi otokorelasyon fonksiyonunun (PACF) incelenmesi veya durağanlaşmaya dek farklarının alınması ile yapılabilir [22]. Pythonun 'statsmodels' kütüphanesinden 'plot_acf, plot_pacf' sınıfları ile bu fonksiyonların görüntülenmesi sağlanmıştır. Şekil 8' de grafiklere bakıldığında seride anormal artış veya azalışlar bulunmamakta yani seri durağan gözükmemektedir. Ayrıca ACF ve PACF grafikleri ARIMA modellerindeki p ve q parametrelerini belirlemek içinde kullanılır. Bu grafiklerde güven aralığını aşan değerlerin (mavi boyalı alanları aşan dikey çizgi sayısı) sayıları p ve q parametresi olarak seçilir. Serinin ACF ve PACF grafikleri Şekil 8 üzerinden incelendiğinde her iki grafikte güven aralığını aşan değer sayısı birdir. Bu da bize p ve q parametreleri 1 değerinde iken ARIMA modellerinde en iyi performansın sağlanabileceğini göstermektedir.

Sonuç olarak bu aşamada tek değişkenli zaman serisi bileşenlerinin grafikleri, dickey fuller testi ve ACF-PACF grafikleri ile durağanlık analizi yapılmış serinin durağan olduğu sonucuna varılmış yani fark alma işlemine gerek kalmamıştır.

3.4.2 ARIMA (p,d,q)

1970' te George Box ve Gwilym Jenkins tarafından geliştirilmiş olan ARIMA modeli, otoregresif metotun (AR), hareketli ortalamalar (MA) ile birleştirilmesidir. ARIMA modeli 3 parametreden oluşan bir modeldir. Bu parametreler (p,d,q) şeklindedir. Anlamları ise p AR modelin derecesi, d durağanlığı sağlamak için serinin hangi dereceden farkının alınması gerektiğini, q ise MA modelin derecesidir [23].

Otoregresif Bütünleşik Hareketli Ortalamalar yani ARIMA modeli zaman serilerinde kullanılan sayısal bir modeldir. Tek veya çok değişkenli seriler üzerinde uygulanabilir. Ancak çoğunlukla tek değişkenli ARIMA yöntemi tercih edilir [9]. Bizde bu projede ilk olarak oluşturduğumuz tek değişkenli zaman serisi üzerinden ARIMA modelini uygulayacağız.

Zaman serilerinde en iyi parametre kombinasyonunu belirlemek için, yani uygun model seçimi için AIC (Akaike bilgi kriteri) ve BIC (Schwartz Bayesci bilgi kriteri) kriterleri kullanılır [24]. AIC değeri ne kadar düşüğe model iyidir. Yani en iyi tahmin modeli için AIC değerinin en düşük olduğu parametre kombinasyonu seçilir.

Bu projede ARIMA modelleri için otomatik ARIMA kullanılmıştır. Otomatik ARIMA en düşük AIC değerlerini ve en iyi parametre kombinasyonları bulmayı sağlayan bir yöntemdir. Burada otomatik ARIMA kullanılma sebebi her ne olursa olsun bir önceki aşamada zaman serisi analizi ile serinin durağan olduğunun ve p ile q parametre değerlerinin 1, d parametresinin 0 olarak belirlenmesine karşın doğru analiz ve seçimlerin yapıldığının kontrolünün yapılması içindir. Ayrıca daha düşük AIC ve BIC değerleri sağlayan parametre kombinasyonları bulunabilir. 'pmdarima' kütüphanesinden 'auto_arima' modeli temin edilmiş, p ve q değerleri için en düşük değer 1, en yüksek değer 3 ve d değeri ise manuel olarak önce 0 ve sonra 1 olarak verilerek her kombinasyon denenmiş ve en iyi sonuç veren kombinasyon (1,0,1) olarak yani baştaki kendi belirlediğimiz parametrelerin olduğu gözlemlenmiştir. Bu da bize doğru analiz yaptığımızı kanıtlamaktadır. Buradan eğitim veri setimizi belirlenen en iyi parametrelerle eğiterek tahmin işlemi yapıldı.

3.4.3 SARIMA (Seasonal ARIMA) (p,d,q) X (P,D,Q,S)

Mevsimsel ARIMA modeli, mevsimsel ve mevsimsel olmayan faktörleri tek bir modelde birleştiren ARIMA modelidir. Bu modelin parametreleri p mevsimsel olmayan AR sırası, d mevsimsel olmayan durağanlık farkı, q mevsimsel olmayan MA sırası, P mevsimsel AR sırası, D mevsimsel farkı, Q mevsimsel MA sırası ve son bileşen S ise tekrar eden mevsimselliğin zaman aralığı yani dönemdir ve aylık veriler üzerinde bu değer 12 olarak ayarlanır [25].

Yine otomatik ARIMA ile SARIMA modelinin parametre değerleri için optimum parametre kombinasyonu bulunmaya çalışıldı. p ve q değerleri en düşük 1, en yüksek 3; d değeri önce 0 sonra 1 olarak verilmiş; bu model mevsimselliğin olduğu varsayılarak denendiği için seriyi mevsimsellikten arındırmak için D değeri 1; P parametresinin başlangıç değeri 0; period 12 ve seasonal parametresi ise True olarak ayarlandı. En düşük AIC değerine (0,0,0) (1,1,1) kombinasyonunda ulaşıldı. Bu parametreler ile model eğitilerek tahmin işlemi gerçekleştirildi.

3.4.4 SARIMAX (Seasonal ARIMA with Exogenous Variables) (p,d,q) X (P,D,Q,S)

SARIMAX (Dışsal Faktörlere Sahip Mevsimsel Otomatik Gerileyen Entegre Hareketli Ortalama) modeli, aslında doğrusal bir regresyon modelidir. Mevsimselliğin olduğu bir tahmin işleminde kullanılan SARIMA modelinin alternatifidir. SARIMA modelinden ayıran özelliği adından anlaşılacağı üzere dışsal faktörleri de ele alması yani bağımsız değişkenleride dahil ederek hata oranını azaltmayı, performansını arttırmayı hedefleyen bir modeldir [26].

Bir önceki ARIMA modellerinde kullandığımız otomatik ARIMA' da p ve q değerlerini en düşük 1, en yüksek 3; d değeri önce 0 ardından 1; D değeri 1; P parametresinin başlangıç değeri 0; period 12 ve seasonal parametresi ise True olarak ayarlandı. X_train bağımsız değişkenleri

ve y_train hedef değişkeni ile eğitim yapıldı. En düşük AIC değerine (0,0,0) (1,1,1) kombinasyonunda ulaşılmış ve tahmin işlemi gerçekleştirilmiştir.

3.4.5 LSTM (Long Short-Term Memory)

LSTM, hücre durumunun tanıtılarak sırası ile her verinin işlendiği bir RNN türüdür. Klasik bellek yapısına sahip bu model bilgileri hatırlar, unuttur ve ardından ileriye aktarır. Yapay sinir ağlarından olan bu modelde hücre durumunda bilgiler kapı isimli bir yapı tarafından düzenlenir. Giriş, unutma ve çıkış olmak üzere bu üç kapıya sahip modelde her kapı bir sinir ağı katmanıdır [27].

Bu modelde çalışma yapabilmek için öncelikle bağımsız değişkenleri tutan X_train ve X_test veri kümelerinin normalizasyon işlemine tabi tutulması gerekmektedir. LSTM normalize edilmiş verilerle daha iyi performans sağlamaktadır. Normalizasyon işleminin ardından 64 hücreli olacak şekilde normalize edilmiş X_train değerleri ile LSTM modelinin ilk katmanı oluşturulur. Modele aktivasyon fonksiyonu 'relu' olacak şekilde bir yoğun katman eklenir. Oluşturulan modeli derlemek için kayıp fonksiyonu olarak 'mse', optimizör olarak 'adam' optimize edicisi seçilir. Böylece model eğitim aşamasına hazır hale gelir.

Girdi verisi normalize edilmiş X_train, çıktı verileri olarak y_train üzerinden epochs = 100, batch_size = 32, verbose = 1 olacak şekilde parametreler ayarlanarak 100 adımda her bir adımda 32 örnek olacak şekilde model eğitilmiş ardından tahmin işlemi yapılmıştır.

3.4.6 MULTIPLE LINEAR REGRESSION

Regresyon analizi, bir ya da daha çok değişken arasındaki ilişkiyi açıklayan istatistiksel bir yöntemdir. Hedef değişken (bağımlı değişken) tahmin edilirken tek bir bağımsız değişken varsa tekli (simple) regresyon; bağımlı değişkeni etkilediğini düşünülen yani aralarındaki ilişkinin bulunmasını istediğimiz bağımsız değişkenler birden fazla ise çoklu (multiple) regresyon kullanılır. Doğrusal regresyonda hedef değişken sayısal deer olmalıdır ancak bağımsız değişkenler kategorik ya da sayısal olabilir. Hedef değişken ile bağımsız değişkenler arasında bir ilişkinin olup olmadığı p değerine bakılarak anlaşılabilir. P değeri %5 anlamlılık düzeyinin altında ise regresyon katsayısı sıfırdan farklıdır yani aralarında doğrusal bir ilişki vardır sonucu çıkarılır [28,29].

Bu modelin matematiksel gösterimi Eşitlik (1)' deki gibidir. Burada B_0 y eksenini kesen nokta, Y hedef değişken (bağımlı değişken), $X_1, X_2, \dots, X_n$ ise bağımsız değişkenler, $B_1, B_2, \dots, B_n$ katsayıları ise eğim yani regresyon katsayısının değeridir.

$$Y = B_0 + B_1 * X_1 + B_2 * X_2 + \dots + B_n * X_n \quad (1)$$

Bu bilgilerden anlaşılacağı üzere çok değişkenli zaman serileri üzerinden yani X_train ve y_train ile Linear Regresyon modeli eğitilerek tahmin işlemi gerçekleştirildi.

3.4.7 HİPER PARAMETRE OPTİMİZASYONU (Grid Search Yöntemi)

Grid search arama yöntemi, hiperparametre ayarlama yöntemlerinden en geleneksel olan yaklaşımdır. Her bir parametreyi geniş bir değer uzayında aramak uzun bir zaman alacağı için modele doğrudan etki edecek belirli değerleri seçmek daha mantıklı bir yöntemdir. Seçilen değerlerin her biriyle kombinasyonlar birleştirilerek bir kartezyen çarpım yapılır. Böylece her bir kombinasyon için model eğitim verileri ile eğitilir. Her bir kombinasyonun denenmesinden kaynaklı hem zaman alan hem de işlem gücü gerektiren bir yapıya sahiptir [30,31].

Bu projede makine öğrenmesi modelleri için oluşturulan grid search arama yönteminde her bir modele uygun olacağı değerlerle parametreler oluşturulmuş, skorlama için MSE seçilmiş, en iyi sonucu veren kombinasyon bulunarak modeller X_train ve y_train eğitim kümeleri ile eğitilip tahmin işlemleri gerçekleştirilmiştir.

3.4.7.1 LightGBM

LightGBM (Light Gradient Boosting Machines), bir Microsoft projesi tarafından geliştirilmiş boosting algoritmasıdır. Bu algoritmayı diğer boosting algoritmalarından ayıran temel özelliği büyük verileri daha kısa sürede işleyip yüksek tahmin oranı vermesidir. Temelinde histogram tabanlı bir çalışma modeli bulunmaktadır. Karar ağaçlarında öğrenme yöntemi seviye odaklı veya yaprak odaklı olmak üzere ikiye ayrılır. Seviye odaklıda ağaç büyürken ağaç dengesi korunur, yaprak odaklıda ise kaybı azaltan yapraklardan bölünme işlemine devam edilir. lightGBM yaprak odaklı yöntem sayesinde daha hızlı öğrenme ve daha az hata oranı

ile tahmin imkanı sunar. Büyük verilerle çalışmada iyi sonuç vermesine karşın veri sayısının az olmasında modelin aşırı öğrenmesi (overfitting) meydana gelebilir [32].

Bu sebepten eğitim verilerinin gözlem birimi sayısı az olduğu için aşırı öğrenmenin önüne geçmek adına Grid search ile parametre optimizasyonu işlemi gerçekleştirilmiştir.

Bu makine öğrenmesi modeli için parametreler; n_estimators: [100, 500, 1000], learning_rate: [0.001, 0.01, 0.1], max_depth: [3, 5, 7], num_leaves: [31, 50, 100] olarak seçilmiş ve en iyi parametre kombinasyonu learning_rate: 0.01, max_depth: 7, n_estimators: 500, num_leaves: 31 olarak belirlenmiştir. Bu parametreler üzerinden tahmin işlemi gerçekleştirilmiştir.

3.4.7.2 CatBoost

2017 yılında Yandex tarafından geliştirilmiş olan CatBoost modeli, kategorik özelliklerle çalışmayı destekleyen karar ağacı temelli bir modeldir. Karar ağaçları üzerinde Gradient Boosting ile geliştirilmiş bu model kategorik özellikli değişkenleri otomatik olarak sayısallaştırarak yüksek performans sağlamayı hedefleyen bir makine öğrenmesi algoritmasıdır. İsmi de bu sebepten ‘Category’ ve ‘Boosting’ kelimelerinden aldığı anlaşılmaktadır [33,34].

Grid search yöntemi için bu modelde iterations: [100, 500, 1000], learning_rate: [0.001, 0.01, 0.1], depth: [3, 5, 7] ve skorumla MSE olarak belirlenmiş en iyi ayara depth: 3, iterations: 500, learning_rate: 0.1’ de ulaşılmış ve tahmin işlemi gerçekleştirilmiştir.

3.4.7.3 XGBoost

XGBoost (eXtreme Gradient Boosting), diğer boosting algoritmalarındaki gibi gradyan arttırım kullanan karar ağacı tabanlı makine öğrenmesi algoritmasıdır. Amacı karar ağacı güçlendirme olan bu algoritma sınıflandırma ve regresyon problemlerini çözmede etkilidir. Güçlendirmeden kasıt, her yeni model bir önceki modeldeki eksiklikleri tespit edip düzelterek yeni bir modeller ekleyerek giden, model zinciri oluşturan toplu öğrenme tekniğidir [35,36].

Bu projede modelin performansını arttırmak için grid search yönteminde iterations: [100, 500, 1000], learning_rate: [0.001, 0.01, 0.1], depth: [3, 5, 7] ve skorumla MSE olarak belirlenmiştir. En iyi performans depth: 3, iterations: 500, learning_rate: 0.1 parametrelerinde tespit edilmiştir. Bu parametre kombinasyonları üzerinden tahmin işlemi yapılmıştır.

3.5 Değerlendirme

CRISP-DM metodolojisinin 5. adımı olan model performanslarının değerlendirilmesi kısmında modelin problem türüne göre bazı değerlendirme yöntemleri bulunmaktadır. Regresyon modelleri için tahmin edilen değerler ile gerçek değerler (tek değişkenli zaman serilerinde test_data, çok değişkenli zaman serisinde y_test) arasında bazı matematiksel hesaplamalarla, sınıflandırma modellerinde ise karşılaştırmak için ise Confusion Matrix (Karışıklık Matrisi) üzerinden bazı hesaplamalar yapılarak oluşturulan performans metrikleri ile modeller değerlendirilebilir. Regresyon modelleri için MAE (Mean Absolute Error), MAPE (Mean Absolute Percentage Error), MSE (Mean squared Error), RMSE (Root Mean Squared Error), R^2 ... ve sınıflandırma problemlerinde ise karışıklık matrisi üzerinden hesaplanan doğruluk, duyarlılık, kesinlik, F1 Score... gibi birçok metrik kullanılır [37,38].

Bu projede modelleri değerlendirmek için MAPE, MSE ve RMSE performans metrikleri tercih edilmiştir.

MAPE (Ortalama Mutlak Yüzde Hata), tahminlerin gerçek değerlere göre yüzde hata oranlarının ortalama mutlak değerini ifade eder. Bu metriğin hesabı için ‘sklearn.metrics’ kütüphanesinden ‘mean_absolute_percentage_error’ ile gerçek değerler ve her bir modelin tahmin değerleri karşılaştırılmıştır.

MSE (Ortalama Karesel Hata), hata karelerinin ortalamasıdır yani veri setindeki orijinal ve tahmin edilen değerler arasındaki farkın karelerinin ortalamasıdır [39]. Bu metriğin hesabı için ‘sklearn.metrics’ kütüphanesinden ‘mean_squared_error’ temin edilmiş ve gerçek değerler ile her bir modelin tahmin değerleri karşılaştırılmıştır. RMSE (Kök Ortalama Kare Hata), MSE’ nin kareköküdür. Bunun içinde yine ‘sklearn.metrics’ kütüphanesinden ‘mean_squared_error’ ile ‘squared’ parametresi ‘False’ ayarlanarak hesaplatılır.


Bu bahsedilen metriklerde değer ne kadar küçükse modelin performansının o kadar yüksek olduğu sonucuna varılır.

Tablo 4. Modellerin MAPE, MSE ve RMSE değerleri

MODEL	MAPE	MSE	RMSE
-------	------	-----	------

Tek Değişkenli			
ARIMA (d=0)	3.40	565.33	23.77
ARIMA (d=1)	4.56	635.91	25.21
SARIMA (d=0)	4.65	2032.13	45.07
SARIMA (d=1)	6.84	2024.24	44.99
Çok Değişkenli			
SARIMAX (d=0)	1.33	140.49	11.85
SARIMAX (d=1)	1.62	248.48	15.76
LSTM	1.15	324.28	18.0
LIGHTGBM	1.10	282.86	16.81
CATBOOST	0.51	145.95	12.08
XGBOOST	0.96	258.56	16.07
MULTIPLE LINEAR REGRESSION	1.64	130.68	11.43


Bu projede uygulanan her bir modelin metrik değerleri tablo 4’ te gösterilmiş, en iyi sonucu CatBoost modelinin verdiği anlaşılmıştır. Bu modelin tahmin değerleri ile y_test veri kümesindeki gerçek değerler karşılaştırılması Şekil 9’ da gösterilmiştir.



Şekil 9: CatBoost Gerçek/Tahmin Değer Karşılaştırılması

3.6 Canlıya Alma

En iyi modelin seçilmesinin ardından CRISP-DM metodolojisinin son adımında CatBoost modeli üzerinden 27 farklı ürünün her biri için veri setinde bulunan ‘2023-03-25’ son tarihinden sonraki 7 günlük süreç için talep tahmini yapılmıştır. Bu işlem için her bir ürünün öncelikle zaman serisini ardından test verisini oluşturmak gerekir. Oluşturulan zaman serileri yani tüm geçmiş veriler eğitim veri seti olarak ayrılır. CatBoost ile 'Discount', 'TotalSales', 'UnitPrice' değişkenleri tahmin edilir. Diğer değişkenler, bu değişkenler ve tarih bilgisi üzerinden yani 'Date' sütunundan hesaplatılır. Burada oluşturulan her bir ürünün serisi ile bahsedilen kolonların her biri tek tek hedef değişken, diğerleri ise bağımsız değişken olarak verilerek tahminleri yapılır. Her tahmin edilen gün eğitim veri setine eklenerek yeni tahmin değerleri ile model beslenir. Son olarak oluşturulan test veri seti ile her bir ürünün 7 günlük ('2023-06-26' – '2023-04-01') talep tahmini yapılmıştır. Taleplerin hepsi Şekil 10’ da gösterilmiştir.



Şekil 10: Ürünlerin Toplam Satış Miktarları

Artık bu proje ile firmalar bahsedilen şekilde geçmiş verileri ile ileriye dönük tahminler yaparak satışların nasıl ilerleyeceği ile depolarının kontrolü ile ilgili bazı çıkarımlar yapabilirler.

4. SONUÇ VE TARTIŞMA

Bu projede perakende sektöründeki bir firmanın satış verileri üzerinden CRISP-DM metodolojisi adımları uygulayarak bazı analizler, veri ön işlemleri ve tahminler yapılmıştır. Proje kapsamında talep tahmini üzerinde kapsamlı bir araştırma yapılarak bilgi toplanmış hangi tekniklerin, modellerin yaygın olarak uygulandığı tespit edilmiştir. Bu projede, firmadaki hangi ürünlerin taleplerinin tahmin edilmeyeceği (satışı duran, satışı yeni başlayan, satışı az olan) ve bunların hangi kıstaslara göre silinmesi gerektiği incelenmiştir. Daha önceki yapılan çalışmaların makaleleri incelendiğinde ARIMA modelleri ve yapay sinir ağları modelleri (özellikle LSTM) uygulanarak karşılaştırılması yapılmış, talep tahmini için hangisinin daha iyi performans sağladığı hususu üzerinde durulduğu gözlemlenmiştir. Makine öğrenmesi modellerinin az incelenmesinden kaynaklı bu projede makine öğrenmesi modellerine de yer verilmiştir. Bu projede çok değişkenli ve tek değişkenli zaman serileri oluşturulup zaman serisi analizi yapılarak bazı çıkarımlarda bulunulmuş hem ARIMA hem yapay sinir ağlarından LSTM hem de makine öğrenmesi modellerinin talep tahmininde nasıl bir performans sağlayacağını tespiti yapılmıştır. Proje kapsamında ARIMA modelleri, LSTM, LightGBM, CatBoost, XGBoost, Multiple Linear Regression modelleri, bazılarında grid search ile, ARIMA modellerine otomatik ARIMA ile parametre ayarları yapılarak talep tahmin işlemi gerçekleştirilmiştir. Model değerlendirmeleri için performans metriklerinden MAPE, MSE, RMSE tercih edilmiş ve en iyi modelin CatBoost olduğu sonucuna varılmıştır. Modellerin performansları incelendiğinde en iyi modellerin makine öğrenmesi modelleri ardından LSTM en sonuncunun ise ARIMA modelleri olduğu sonucuna varılmıştır. Çok değişkenli zaman serileri üzerinden uygulanan modellerin yeni değişkenler türetilmesi ile performanslarının arttığı sonucu gözlemlenmiştir. Son aşamada seçilen model ile her bir ürünün ileriye dönük 7 günlük talep tahmini için bağımsız değişkenler ve bu bağımsız değişkenler üzerinden talep tahmini yapılmıştır. ARIMA modelleri kendi içlerinde incelendiğinde SARIMAX modelinin, modeli bağımsız değişkenler ile beslemesinden kaynaklı ARIMA ve SARIMA' dan daha iyi sonuç verdiği anlaşılmıştır. ARIMA modelinin SARIMA modelinden daha iyi sonuç verme sebebi ise zaman serisi bileşenlerinin incelenmesi yapıldığında bu veri setindeki verilerin bir mevsimsel etki göstermemesinden kaynaklıdır.

Ayrıca veri setleri, firmaların bulunduğu ülke tespit edilerek ödemede kullanılan para birimi ve döviz kurlarının günlük değerleri ile beslenerek taleplerin, piyasanın hareketliliğine göre nasıl etkilendiğinin analizi yapıp, projede kullanılan modellerin performansının artırılması yani daha gerçeğe yakın tahminlerin yapılabilmesi sağlanabilir. Başka değişkenler ile de veri seti ve modeller beslenebilir. Ancak bu sayılan işlemlerin hepsinin tek bir seferde bir projede veri bilimciler tarafından manuel olarak programlama dilleri ve algoritmalarla yapılabilmesinin zorluğuna karşın, günümüz teknolojisinin etkisiyle hem vakitten tasarruf hem de verimlilik artırılması açısından bu işlemlerin her birini no-code (kodlamasız) mantığı ile tek bir çatı altında inceleyen dinamik, hazır yazılımlar geliştirilmektedir. Örneğin çağımızı yakalayan ve günümüz teknolojisinden bir parça olan yapay zekayı kullanarak ürünler ortaya koyan OptiWisdom firması bu gibi konular için çözümler sunmaktadır. Bu bağlamda sayılan hususların gerçekleştirilmesinin 3 adımda mümkün olacağını fikriyle her bir adımı bir motorun üstleneceği motorlar ve bu motorlardan oluşan bir sistem geliştirerek Kolay.ai [40] ürününü ortaya koymuşlardır. Kolay.ai ürününün temelinde; satışların diğer faktörler ile ilişkilerini tespit eden optiMatcher, bu ilişkiler ışığında bazı hesaplamalar ile skorlama işlemi yapan optiScorer [41] ve bu skorlamalar ile verileri anlamaya yönelik gruplama işlemi yapan optisSegment motorları bulunmaktadır. Kolay.ai, geçmiş fatura bilgilerini (satış verileri) bir .CSV dosyası olarak sisteme yüklenerek kar-zarar analizi-tahmini, aylık-haftalık gelir-talep tahminleri, sezonsallık-trend-tortu analizleri, RFM (Sonluk, Frekans, Maliyet) analizi

yöntemi ile müşteri analizleri gibi daha birçok işlem herkesin anlayabileceği arayüz tasarımı sayesinde kendi kendine kullanabilme kolaylığı sunan, kişileştirme imkanını da barındıran özellikle kobi ölçekli firmalar için güzel bir sistemdir.

4. KAYNAKÇA

- [1] Mihriban YÜCESOY, İstanbul Teknik Üniversitesi Fen Bilimleri Enstitüsü, Yüksek Lisans Tezi, “Temizlik Kağıtları Sektöründe Yapay Sinir Ağları İle Talep Tahmini”, HAZİRAN 2011
- [2] YAZICIOĞLU, Nazife. Yapay Zeka İle Talep Tahmini. 2010. PhD Thesis. Bursa Uludag University (Turkey).
- [3] MEHMET, A. C. I.; DOĞANSOY, Gamze AYYILDIZ. Makine öğrenmesi ve derin öğrenme yöntemleri kullanılarak e-perakende sektörüne yönelik talep tahmini. Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi, 2022, 37.3: 1325-1340.
- [4] ÇELİK, Cemal; YELKİKALAN, Nazan. Makine Öğrenme Yöntemlerinin Depo Yönetim Süreçlerinde Uygulanması: Azure ML Studio Örneği. Yaşar Üniversitesi E-Dergisi, 2021, 16.62: 659-682.
- [5] GÜLMEZ, Burak. Zaman serisi analizi ile talep tahmini ve bir fabrikadaki üretim planlama. In: Mühendislik Alanında Uluslararası Araştırmalar. Eğitim Yayınevi, 2022. p. 57-74.
- [6] Sevgi, P. (2012). Hazır giyim perakendeciliği yapan bir firmada yapay sinir ağları ile satış tahmini.
- [7] Claudimar Pereira da Veiga, Cássia Rita Pereira da Veiga, Weslly Puchalski, Leandro dos Santos Coelho, Ubiratã Tortato, Demand forecasting based on natural computing approaches applied to the foodstuff retail segment, Journal of Retailing and Consumer Services, Volume 31, 2016, Pages 174-181, ISSN 0969-6989. from <https://doi.org/10.1016/j.jretconser.2016.03.008>
- [8] GÜVEN, İ. (2020). PERAKENDE HAZIR GİYİM ENDÜSTRİSİNDE YAPAY ZEKA YÖNTEMLERİ İLE TALEP TAHMİNİ (Doctoral dissertation).
- [9] Muhammed Resul AYDIN, Osman YAZICIOĞLU (2019). “YAPAY SİNİR AĞLARI İLE TALEP TAHMİNİ: PERAKENDE SEKTÖRÜNDE BİR UYGULAMA”. İstanbul Ticaret Üniversitesi Fen Bilimleri Dergisi, 18(35), Bahar 2019.
- [10] S. Thomas Ng, Martin Skitmore, Keung Fai Wong, Using genetic algorithms and linear regression analysis for private housing demand forecast, Building and Environment, Volume 43, Issue 6, 2008, Pages 1171-1184, ISSN 0360-1323, from <https://doi.org/10.1016/j.buildenv.2007.02.017>.
- [11] Şeker, Ş. E., & Erdoğan, D. (2018). KNIME İle Uçtan Uca Veri Bilimi. 1.
- [12] YAMAN, Yağız. Müşteri Yolculuğu Analitiğini Makine Öğrenmesi Modeliyle Tahminleme.
- [13] BARUT, Zeynep; BİLGİN, Turgay Tugay. Konut Fiyatlarının Tahmini için Polinomslal Regresyon ve Yapay Sinir Ağları Yöntemlerinin Uygulamalı Karşılaştırılması. Süleyman Demirel Üniversitesi Fen Bilimleri Enstitüsü Dergisi, 2023, 27.1: 152-159.
- [14] Seker, S. E. (2015). Zaman serisi analizi (Time Series Analysis). YBS Ansiklopedi, 2(4), 23-31.
- [15] Demirbaş, F. P. (2011). Kombi üretiminde talep tahmin yöntemlerinin uygulanması (Master's thesis, Kocaeli Üniversitesi, Fen Bilimleri Enstitüsü).
- [16] Şadi Evren ŞEKER, “Retail Data Set”, Mayıs 2023. from <https://www.kaggle.com/datasets/shedai/retail-data-set>
- [17] ÖZMEN, A., & POYRAZ, K. (2015). ZAMAN SERİLERİNİ MEVSİMLİK ETKİDEN ARINDIRMADA UYGUN TEKNİĞİN BERLİRLİNEŞİNE İLİŞKİN BİR YAKLAŞIM. Dumlupınar Üniversitesi Sosyal Bilimler Dergisi, (3).
- [18] Beşel, C., & Kayıkcı, E. T. (2016). Meteorolojik verilerin zaman serisi ve tanımlayıcı istatistikler ile yorumlanması; Karadeniz Bölgesi örneği. TÜCAUM Uluslararası Coğrafya Sempozyumu, (S. 50-69). Ankara.
- [19] Galip ALTINAY (2010). “Aylık Elektrik Talebinin Mevsimsel Model ile Orta Dönem Öngörüsü”. Enerji, Piyasa ve Düzenleme, Cilt:1, Sayı:1, Sayfa 1-23, 2010
- [20] Uzgören, N., & Uzgören, E. (2005). ZAMAN SERİLERİNDE SAHTE REGRESYON SORUNU VE REEL KAMU HARCAMALARINA YÖNELİK BİR EKONOMETRİK MODEL UYGULAMASI. from <https://www.acarindex.com/dosyalar/makale/acarindex-1423868404.pdf>
- [21] GİZEM, B. A. Ş.; MEHMET, K. A. R. A. Türkiye’de döviz kuru ile sorunlu krediler ilişkisi: bir zaman serisi analizi. Kafkas Üniversitesi İktisadi ve İdari Bilimler Fakültesi Dergisi, 2020, 11.22: 997-1023.
- [22] ERTUĞRUL, İ., & BEKİN, A. (2016). TÜRKİYE’DE BAZI TEMEL GIDA FİYATLARI İÇİN YAPAY SİNİR AĞLARI VE ZAMAN SERİSİ TAHMİN MODELLERİNİN KARŞILAŞTIRMALI ANALİZİ. Kafkas Üniversitesi İktisadi ve İdari Bilimler Fakültesi Dergisi, 7(13), 253-280.

- [23] Tuğba, S. A. R. I., & GÜL, B. S. (2022). BÜTÜNLEŞİK ZAMAN SERİSİ ANALİZİ İLE TALEP TAHMİNİ: İLAÇ TEDARİK ZİNCİRİNDE BİR UYGULAMA. Verimlilik Dergisi, (4), 597-610.
- [24] ALTUNKAYNAK, A., & BAŞAKIN, E. (2018). Zaman serileri kullanılarak nehir akım tahmini ve farklı yöntemlerle karşılaştırılması. Erzincan University Journal of Science and Technology, 11(1), 92-101.
- [25] Adanacioglu, H., & Yercan, M. (2012). An analysis of tomato prices at wholesale level in Turkey: an application of SARIMA model. Custos e@ gronegocio on line, 8(4), 52-75.
- [26] Abeltino, A., Bianchetti, G., Serantoni, C., Riente, A., De Spirito, M., & Maulucci, G. (2023). Putting the personalized metabolic avatar into production: A comparison between deep-learning and statistical models for weight prediction. Nutrients, 15(5), 1199.
- [27] Mehdizadeh Dastjerdi, A., & Morency, C. (2022). Bike-sharing demand prediction at community level under COVID-19 using deep learning. Sensors, 22(3), 1060.
- [28] GABRALI, D., & Aslan, Z. (2020). Güneş enerjisi potansiyelinin çoklu lineer regresyon ve yapay sinir ağları ile modellenmesi. AURUM Journal of Engineering Systems and Architecture, 4(1), 23-36.
- [29] Kılıç, S. (2013). Doğrusal regresyon analizi. Journal of Mood Disorders, 3(2), 90-92.
- [30] Murat, E. M. E. Ç., & ÖZCANHAN, M. H. (2023). Makine Öğrenmesi Algoritmalarında Hiper Parametre Belirleme. MÜHENDİSLİKTE ÖNCÜ VE ÇAĞDAŞ ÇALIŞMALAR, 71-98.
- [31] Özcan, T., & Baştürk, A. (2020). ERUSLR: Yeni bir Türkçe işaret dili veri seti ve hiperparametre optimizasyonu destekli evrişimli sinir ağı ile tanınması. Gazi Üniversitesi Mühendislik Mimarlık Fakültesi Dergisi, 36(1), 527-542.
- [32] Emre Rıdvan Muratlar (2020). "LightGBM". veribilimiokulu.com. <https://www.veribilimiokulu.com/lightgbm/>. 29 Nisan 2020
- [33] Zhou, F., Pan, H., Gao, Z., Huang, X., Qian, G., Zhu, Y., & Xiao, F. (2021). Fire prediction based on catboost algorithm. Mathematical Problems in Engineering, 2021, 1-9.
- [34] Sanjeetha, R., Raj, A., Saivenu, K., Ahmed, M. I., Sathvik, B., & Kanavalli, A. (2021). Detection and mitigation of botnet based DDoS attacks using catboost machine learning algorithm in SDN environment. International Journal of Advanced Technology and Engineering Exploration, 8(76), 445.
- [35] KURT, Anıl, Burak BULDU, and İsmail Hakkı CEDİMOĞLU. "XGBOOST VE RASTGELE ORMAN ALGORİTMALARININ AĞ TABANLI SALDIRI TESPİTİNE YÖNELİK PERFORMANSLARININ KARŞILAŞTIRILMASI."
- [36] Mitchell, R., & Frank, E. (2017). Accelerating the XGBoost algorithm using GPU computing. PeerJ Computer Science, 3, e127.
- [37] Serdar Tıfıralı (2022). "Yapay Öğrenme: Model Başarı Değerlendirme Yöntemleri". Medium.com . <https://medium.com/machine-learning-t%C3%BCrkiye/yapay-%C3%B6%C4%9Frenme-model-ba%C5%9Far%C4%B1-de%C4%9Ferlendirme-y%C3%B6ntemleri-e0f3539e211c>. 16 Mayıs 2022.
- [38] Şevket Ay. "Model Performansını Değerlendirmek — Metrikler". Medium.com . <https://medium.com/deep-learning-turkiye/model-performans%C4%B1n%C4%B1-de%C4%9Ferlendirmek-metrikler-cb6568705b1>. 30 Nisan 2020
- [39] ÖNGÜN, Mustafa (2023). Çok Değişkenli Finansal Zaman Serisi Analizinde Yapay Zekanın Kullanımı. YBS Ansiklopedi, Cilt: 11, Sayı: 1, Ocak 2023.
- [40] Seker, S. E. (2015). KOBİ'lere Özel Basit Yapay Zeka Çözümü: Kolay.AI. YBS Ansiklopedi, Cilt: 11, Sayı: 1, Ocak 2023.
- [41] Şeker, Ş. E. (2020). OptiScorer: Otomatik Makine Öğrenmesi ile Skorlama. YBS Ansiklopedi, Cilt: 8, Sayı: 1, Ocak 2020.