

MİMAR SİNAN GÜZEL SANATLAR ÜNİVERSİTESİ ★ FEN BİLİMLERİ
ENSTİTÜSÜ

**GERİ DÖNÜŞLÜ DERİN SİNİR AĞLARI İLE ZAMAN SERİSİ TAHMİNİ VE BİR
FİNANS UYGULAMASI**

DOKTORA TEZİ

Necati Serdar PEKMEZCİ

Anabilim Dalı: İstatistik

Programı: İstatistik

Tez Danışmanı: Doç. Dr. Semra ERPOLAT TAŞABAT

HAZİRAN 2019


Necati Serdar Pekmezci tarafından hazırlanan Geri Dönürlü Derin Sinir Ağları ile Zaman Serisi Tahmini ve Bir Finans Uygulaması adlı bu tezin Doktora tezi olarak uygun olduğunu onaylarım.


Doç. Dr. Semra Erpolat Tarabacı


Tez Yöneticisi

Bu çalışma, jürimiz tarafından İstatistik Anabilim Dalında Doktora tezi olarak kabul edilmiştir.

Başkan

: Doç. Dr. Semra Erpolat Tarabacı 

Üye

: Prof. Dr. M. Aydın Ezer 


Üye

: Prof. Dr. Nalan Cinekire 

Üye

: Dr. Yalçın Erkan 

Üye


: Doç. Dr. Ersoy Öztürk 

Bu tez, Mimar Sinan Güzel Sanatlar Üniversitesi Fen Bilimleri Enstitüsü tez yazım kurallarına uygundur.

Mimar Sinan Güzel Sanatlar Üniversitesi Fen Bilimleri Enstitüsü tez yazım kılavuzuna uygun olarak hazırladığım bu tez çalışmada;

- Tez içindeki bütün bilgi ve belgeleri akademik kurallar çerçevesinde elde ettiğimi,
- Görsel, işitsel ve yazılı tüm bilgi ve sonuçları bilimsel etik kurallarına uygun olarak sunduğumu,
- Başkalarının eserlerinden yararlanılması durumunda ilgili eserlere bilimsel normlara uygun olarak atıfta bulunduğumu,
- Atıfta bulunduğum eserlerin tümünü kaynak olarak gösterdiğimi,
- Kullanılan verilerde herhangi bir değişiklik yapmadığımı,
- Ücret karşılığı başka kişilere yazdırmadığımı (dikte etme dışında), uygulamalarımı yaptırmadığımı,
- Ve bu tezin herhangi bir bölümünü bu üniversite veya başka bir üniversitede başka bir tez çalışması olarak sunmadığımı

Beyan ederim.


N. Serdar PEKMEZCİ
27.05.2019

ÖNSÖZ

Tez çalışmamda ve M.S.G.S.Ü. öğrencilik dönemimde desteğini esirgemeyen,engin bilgi ve tecrübelerinden yararlandığım, yönlendirme ve bilgilendirmeleriyle çalışmamı bilimsel temeller ışığında şekillendiren Sayın Hocalarım Tez Danışmanım Doç. Dr. Semra ERPOLAT TAŞABAT’a, Tez İzleme Komitesi Üyelerim Prof. Dr. Nalan CİNEMRE ve Dr. Yalçın ÖZKAN’a sonsuz teşekkürlerimi sunarım. Tüm eğitim hayatım boyunca benden desteklerini esirgemeyen her zaman yanımda olan sevgili anne ve babama teşekkürlerimi bir borç bilirim.

PREVIEW

GERİ DÖNÜŞLÜ DERİN SİNİR AĞLARI İLE ZAMAN SERİSİ TAHMİNİ VE BİR FİNANS UYGULAMASI

ÖZET

Zaman serileri tahminleri enerji, meteoroloji, ekonomi, mühendislik ve finansal v.b. alanlarda zamana göre değişen verilerde gelecekteki sonuçları tahmin etmek için kullanılmaktadır. Bu tahminleri yapabilmek çevresel, sosyal ve ekonomik koşullar gibi dış etkilere de bağlıdır. Zaman serileri üzerinde yapılan tahmin çalışmalarında çeşitli istatistiksel yöntemler kullanılmaktadır. Regresyon yöntemleri yanı sıra Auto Regressive Integrated Moving Average (ARIMA) modellerinin de başarıyla uygulandığı bilinmektedir. Literatürde zaman serileri ile ilgili tahmin süreçlerinde istatistik yöntemlerin dışında makine öğrenmesi yöntemlerinin de kullanılmaya başlandığı görülmüyor. Özellikle derin öğrenme modellemesine dayalı olarak derin öğrenme ağlarının zaman serilerinde de başarılı olabileceği yönünde literatürde yeterli sayıda çalışma henüz mevcut değildir. Bu tez kapsamında çeşitli makine öğrenmesi yöntemleri ele alınarak makine öğrenmesi algoritmalarının başarılı tahmin modellerinin elde edilmesinde zaman serilerine nasıl uygulanabileceğinin ortaya konulması amaçlanmaktadır.

Modern yapay sinir ağları arasında Derin Öğrenme Sinir Ağları, Geri Dönüşlü Sinir Ağları (RNN: Recurrent Neural Networks) ve Uzun-Kısa Süreli Bellek Ağları (LSTM: Long Short Term Memory Networks) önemli bir yer tutmaktadır. Bu tür ağlar zaman serilerine uyarlanarak tahmin işlemlerinde kullanılabilir. Çalışmamızda bu algoritmalara dayalı olarak T.C. Merkez Bankası döviz kurlarına yönelik olarak geliştirilen bir öngörü modelinin ortaya konulması amaçlanmaktadır.

TIME SERIES FORECASTING WITH RECURRENT DEEP NEURAL NETWORKS AND A FINANCE APPLICATION

ABSTRACT

Time series estimations are used to predict future results in time-varying data in the fields of energy, meteorology, economics, engineering and financing, etc. Making these estimations depends on external factors such as environmental, social and economic conditions. Various statistical methods are used in the estimation studies on time series. In addition to regression methods, Auto Regressive Integrated Moving Average (ARIMA) models are known to be applied successfully. In the literature, it is seen that machine learning methods are used in addition to statistical methods in the estimation processes related to time series. There are not sufficient number of studies in the literature showing that deep learning networks can be successful in time series based on especially deep learning modeling. Within the scope of this thesis, it is aimed to show how machine learning algorithms can be applied to time series in obtaining successful prediction models by discussing various machine learning methods.

Among the modern artificial neural networks, Deep Learning Neural Networks, Recurrent Neural Networks (RNN) and Long-Term Memory Networks (LSTM) take an important place. Such networks can be used in prediction by adapting to time series. In our study, it is aimed to put forward a prediction model developed for the exchange rates of the Central Bank based on these algorithms.

İÇİNDEKİLER

1. GİRİŞ	1
2. MAKİNE ÖĞRENMESİ	3
2.1. MAKİNE ÖĞRENMESİ TÜRLERİ.....	4
2.1.1. Denetimli öğrenme (Supervised Learning).....	5
2.1.2. Denetimsiz öğrenme (Unsupervised Learning)	6
2.1.3. Pekiştirmeli Öğrenme (Reinforcement Learning).....	7
2.2. MAKİNE ÖĞRENMESİ UYGULAMALARI	8
2.2.1. Sınıflandırma (Classification)	9
2.2.2. Kümeleme (Clustering).....	10
2.2.3. Birliktelik Kuralları (Association Rules)	11
2.3. DENETİMLİ ÖĞRENME ALGORİTMALARI	12
2.3.1. Sınıflandırma Modeli Elde Etme Süreci	12
2.3.2. Veri Önışleme.....	13
2.3.2.1. Veri Temizleme	14
2.3.2.2. Veri Entegrasyonu	15
2.3.2.3. Veri Azaltma	15
2.3.2.4. Veri Dönüşümü	15
2.3.2.4.1. Min- Max Normalleştirilmesi.....	15
2.3.2.4.2. Z- Score Standartlaştırma	16
2.3.3. Karar Ağaçları Yoluyla Sınıflandırma	16
2.3.3.1. Entropiye Dayalı Algoritmalar.....	18
2.3.3.1.1. ID3 Algoritması	18
2.3.3.1.2. C4.5 Algoritması	19
2.3.3.3. Sınıflandırma ve Regresyon Ağaçları (CART)	19
2.3.3.3.1. Twoing Algoritması.....	19
2.3.3.3.2. Gini Algoritması	20
2.3.4. K-en yakın komşu algoritması.....	21
2.3.5. Destek Vektör Makinesi (Support Vector Machine).....	23
2.3.5.1. Doğrusal Destek Vektör Makineleri	23
2.3.5.2 Doğrusal Olmayan Destek Vektör Makineleri	24
2.3.6. Yapay Sinir Ağları.....	25
2.3.6.1. Yapay Sinir Hücresi	26
2.3.6.2. Yapay Sinir Ağlarının Sınıflandırılması.....	29
2.3.6.2.1. İleri Beslemeli Yapay Sinir Ağları.....	29
2.3.6.2.2. Geri Beslemeli Yapay Sinir Ağı	30
2.3.7. Öngörü Modellerinin performansı	31
3. ZAMAN SERİLERİ ANALİZİNDE GERİ DÖNÜŞLÜ DERİN YAPAY SİNİR AĞLARI	33

3.1. İSTATİSTİKSEL ZAMAN SERİSİ ANALİZLERİ: ARIMA MODELİ İLE TAHMİN	33
3.1.2. Otoresif bütünleşmiş hareketli ortalamalar (ARIMA) yöntemi	34
3.2. DERİN ÖĞRENME (DEEP LEARNING)	35
3.3. DERİN ÖĞRENME MİMARİLERİ	38
3.3.1. Geri Dönüşlü (Recurrent) Derin Öğrenme Ağları (RNN)	39
3.3.2. Uzun Kısa Dönemli Bellek (LSTM) Ağları	42
3.3.3. Konvolüsyonel Sinir Ağları Modeli (Convolutional Neural Network-CNN)	46
3.3.3.1. Konvolüsyon katmanı	47
3.3.3.2. Havuzlama Katmanı	48
3.3.3.3. Tam Bağlı Katman	49
3.4. ZAMAN SERİLERİNDE GERİ DÖNÜŞLÜ DERİN ÖĞRENME AĞLARI İLE ÖNGÖRÜ	49
4. UYGULAMA: DÖVİZ KURLARI ZAMAN SERİSİNDEKİ DEĞİŞMELERİN GERİ DÖNÜŞLÜ LSTM DERİN SİNİR AĞLARI İLE ANALİZİ	51
4.1. GİRİŞ	51
4.2. DERİN YAPAY SİNİR AĞLARI ALGORİTMALARI İLE ZAMAN SERİSİ ANALİZLERİ	52
4.3. VERİ KÜMESİ	53
4.4. DERİN ÖĞRENME İLE ZAMAN SERİLERİNDE ÖNGÖRÜ ELDE ETMEK İÇİN GELİŞTİRİLEN BİR METODOLOJİ	58
4.5. VERİ MİKTARININ PLANLANMASI	61
4.6. ÖNİŞLEME	61
4.6.1. Değer içermeyen satırların silinmesi	62
4.6.2. Normalizasyon işlemleri	62
4.6.3. Veri kümesinin eğitim ve test amacıyla bölünmesi	63
4.7. ÖZNİTELİKLERİN SEÇİLMESİ	64
4.7.1. Özniteliklerin seçilmesinde kullanılan model mimarisi	66
4.7.2. Modelin elde edilmesi	68
4.7.3. Modelin test verisiyle performansı	70
4.8. SEÇİLEN ÖZNİTELİKLERE GÖRE LSTM MODELİNİN YENİDEN OLUŞTURULMASI	73
4.8.1. Model mimarisi	74
4.8.2. Modelin elde edilmesi	75
4.8.3. Seçilen LSTM modeli ile öngörü	75
4.8.4. Sonraki öngörüler	76
4.9. KONVOLÜSYONEL LSTM MODELİ İLE ÖNGÖRÜ	77
4.9.1. CNN-LSTM modelinin test verisiyle performansını belirleme	78
4.9.2. Model mimarisi	78
4.9.3. Modelin elde edilmesi	79
4.9.4. CNN-LSTM modelinin öngörü amacıyla düzenlenmesi ve performansı	82
4.10. SONUÇ	83

5. KAYNAKÇA	86
-------------------	----

PREVIEW

KISALTMALAR

RNN	: Recurrent Neural Networks
LSTM	: Long Short Term Memory Networks
GPRS	: General Packet Radio Service
CART	: Sınıflandırma ve Regresyon Ağaçları
ID3	: İteratif Dichotomiser 3 Algoritması
KNN	: K Nearest Neighbour
DVM	: Destek Vektör Makineleri
SVM	: Support Vector Machine
YSA	: Yapay Sinir Ağları
ARIMA	: Autoregressive İntegrated Moving Average
SARIMA	: Seasonal Autoregressive Integrated Moving Average
CNN	: Convolutional Neural Network

ŞEKİL LİSTESİ

Şekil 2.1 Makine öğrenmesi çalışma prensibi.....	4
Şekil 2.2 Makine öğrenmesi türleri.....	5
Şekil 2.3 Denetimli öğrenme örneği.....	6
Şekil 2.4 Pekiştirmeli öğrenme şeması.....	8
Şekil 2.5 Sınıflandırma sınırları örneği.....	10
Şekil 2.6 Kümeleme işlemi örneği.....	11
Şekil 2.7 Sınıflandırma modeli çalışma şeması.....	13
Şekil 2.8 Veri işleme süreci.....	14
Şekil 2.9 Karar ağacı örneği.....	17
Şekil 2.10 K- En yakın algoritması örneği.....	22
Şekil 2.11 Destek Vektör Makineleri.....	24
Şekil 2.12 Yapay sinir ağları.....	26
Şekil 2.13 İnsan sinir hücreleri yapısı.....	26
Şekil 2.14 Yapay sinir hücresi yapısı.....	27
Şekil 2.15 Bazı toplama fonksiyonları.....	28
Şekil 2.16 Bazı aktivasyon fonksiyonları.....	29
Şekil 2.17 İleri beslemeli yapay sinir ağı.....	30
Şekil 2.18 Geri beslemeli yapay sinir ağı.....	31
Şekil 3.1 Yapay sinir ağı ve derin öğrenme sinir ağı karşılaştırma.....	36
Şekil 3.2 Derin öğrenme performans grafiği.....	37
Şekil 3.3 İnsan resminin derin öğrenme ile katmanları.....	38
Şekil 3.4 RNN dizilerinden bazı örnekler.....	40
Şekil 3.5 RNN yapısı.....	40
Şekil 3.6 İleri ve geriye doğru RNN yapısı.....	42
Şekil 3.7 LSTM'deki yinelenen modül ve katmanlar yapısı.....	43
Şekil 3.8 LSTM yapısı içeriği.....	43
Şekil 3.9 Detaylı LSTM yapısı.....	44
Şekil 3.10 Dijital görüntülerin arkasındaki veri yapısı.....	47
Şekil 3.11 Konvolisyon katmanı işlemi.....	48
Şekil 3.12 Havuzlama katmanı örneği.....	49
Şekil 4.1 Döviz kurlarındaki 03/01/2000 ile 22/03/2019 tarihi arasındaki değişimler.....	56
Şekil 4.2 Veri kümesine ilişkin histogram.....	57

Şekil 4.3 Gecikmelere dayalı yoğunluk grafiği.....	58
Şekil 4.4 Döviz kurlarıyla ilgili gözlem değerleri arasındaki otokorelasyon.....	58
Şekil 4.5 Merkez Bankası USD/TR döviz kurlarından geri dönüşlü yapay sinir ağları ile öngörü elde etme metodolojisi.	60
Şekil 4.6 Özniteliklerin seçim süreci.....	61
Şekil 4.7 İleriye yönelik öngörülerin geliştirilmesi süreci.	61
Şekil 4.8 Eğitim veri kümesi	63
Şekil 4.9 Test veri kümesi	64
Şekil 4.10 Geri dönüşlü derin sinir ağlarının veri modeli.	66
Şekil 4.11 Eğitim veri kümesine dayalı olarak model hatasındaki gelişmeler.....	69
Şekil 4.12 Doğrulama verisinden elde edilen hata grafiği.	70
Şekil 4.13 Öznitelik sayıları ve hata miktarları arasındaki ilişki.	72
Şekil 4.14 LSTM modeli yardımıyla elde edilen öngörülerin test verisiyle karşılaştırılması..	73
Şekil 4.15 CNN-LSTM modeli.	77
Şekil 4.16 Model Hatası	80
Şekil 4.17 Doğrulama Hatası	81
Şekil 4.18 Test Verisi ve Öngörüler.....	82

1. GİRİŞ

Zaman serileri üzerinde yapılan tahmin çalışmalarında çeşitli istatistiksel yöntemler kullanılmaktadır. Regresyon yöntemleri yanı sıra ARIMA modellerinin de başarıyla uygulandığı bilinmektedir. Literatürde zaman serileri ile ilgili tahmin süreçlerinde istatistik yöntemlerin dışında makine öğrenmesi yöntemlerinin de kullanılmaya başlandığı görülüyor. Özellikle derin öğrenme modellemesine dayalı olarak derin öğrenme ağlarının zaman serilerinde de başarılı olabileceği yönünde literatürde yeterli sayıda çalışma henüz mevcut değildir. Bu tez kapsamında çeşitli makine öğrenmesi yöntemleri ele alınarak makine öğrenmesi algoritmalarının başarılı tahmin modellerinin elde edilmesinde zaman serilerine nasıl uygulanabileceğinin ortaya konulması amaçlanmaktadır.

Modern yapay sinir ağları arasında Derin Öğrenme Sinir Ağları, Geri Dönürlü Sinir Ağları (RNN: Recurrent Neural Networks) ve Uzun-Kısa Süreli Bellek Ağları (LSTM: Long Short Term Memory Networks) önemli bir yer tutmaktadır. Bu tür ağlar zaman serilerine uyarlanarak tahmin işlemlerinde kullanılabilir. Çalışmamızda bu algoritmalara dayalı olarak geliştirilen bir öngörü modelinin ortaya konulması amaçlanmaktadır.

Özellikle 2018-2019 döneminde Türk lirasının yabancı paralar karşısındaki değeri oldukça dalgalı bir seyir izlemektedir. Bu durum döviz kurlarının tahmininde zorluklara neden olmakta, güvenilir tahmin modellerinin bulunmasını gerekli kılmaktadır. Bu çalışma üç belirgin noktada farklı öneriler sunmaktadır. Bunlardan birincisi, zaman serisinden elde edilen otoregresif veri modeli özneliliklerinin geri dönürlü LSTM yapay sinir ağlarını kullanarak seçilebileceğine ilişkindir. Diğeri ise öngörülerin oluşturulması esnasında son modelden elde edilen öngörünün veri kümesine eklenmesi, yeni bir geri dönürlü LSTM modeli oluşturularak ardışık olarak parametrelerinin her defasında yeniden düzenlenmesi, çalıştırılması ve öngörülerin elde edilmesidir. Bir diğeri sonuç, Merkez Bankası USD/TL verilerinden elde edilen LSTM modelinin, aynı aileden olan konvolüsyonel LSTM modeline göre daha başarılı öngörüler geliştirme yeteneğinin ortaya konulmasıdır.

Yapay zekâ, insanlar gibi davranmasını ve aynı özellikleri göstermesini istediğimiz makinelere öğrenme yeteneği verme kavramıdır. İnsana özgü davranış gösterme hissetme, öngörme ve karar verme gibi işleri yapabilen teknolojinin genel adıdır. Bilişim sektörünün günümüzde hızla gelişmesi ile yapay zekâ kavramı da hızla gelişmektedir. 1980'li yıllarda özellikle alım satım modellerini destekleyen algoritmalar talimatlara dayalı programlardır. Detaylı bir işlemler dizisini takip etmek üzere tasarlanan ilk algoritmalar

yalnızca açıkça tanımlanmış veri ve değişkenlere dayanarak hareket edebilirdi. Bu algoritmalar, sayısallaştırılmış verilerin kullanılabilirliği ve bunları çalıştıran sistemlerin işlem gücü ile sınırlıdır.

Veri boyutlarının genişlemesi ve bilgisayar donanımlarının artmasıyla yazılımcılar parametrelere sıkı sıkıya bağlı olmayan algoritmalar tasarlamaya başlamışlardır. Bireysel internet kullanımının artması ile eğlence, tüketim, pazarlama ve perakende işlemlerinden toplanan binlerce değişken ve milyarlarca kayıt içeren veri kümeleri oluşmuştur. Algoritmaların karmaşıklığı ve veri hacmi yeni veri işleme yöntemlerini destekleme ihtiyacına yol açmıştır.

2010 yılından bu yana özellikle finansal teknolojinin yükselmesi ile bilişimciler, bilgi teknolojisi şirketleri ve finans şirketleri yapay zekâ alanına yoğunlaşmaya başlamışlardır. Bu durum oluşan yüksek hacimdeki verilerden faydalı bilgiler elde etme ve bu bilgileri kullanma ihtiyacından kaynaklanmaktadır.

Yapay Zekâ, Makine Öğrenmesi ve Derin Öğrenme kavramları birbiri ile ilişkili kavramlar olmakla birlikte Makine Öğrenmesi Yapay Zekânın, Derin Öğrenme ise Makine Öğrenmesinin gelişen süreçte oluşan alt kümesidir. Bu tez kapsamında ilerleyen bölümlerde bu kavramlara açıklık getirilmektedir.

2. MAKİNE ÖĞRENMESİ


Günümüzde makine öğrenmesi bir problemin çözümünde var olan verilerden anlamlı ilişkiler çıkarılarak tahminlerde bulunmak ya da insanların günlük hayattaki deneyimlerinden faydalanarak bir işi makine öğrenme teknikleri kullanılarak bilgisayarlar aracılığı ile sıklıkla çözülmeye çalışılan yöntemler haline gelmiştir. Makine öğrenmesi, bilgisayar yazılımlarıyla mevcut verilerden elde edilen deneyimlerin, gelecekteki olayları tahmin etmesine ve modelleme yapmasına imkân veren bir yapay zekâ alanıdır [1].

Yapay zekâ günümüzde gerek uygulama alanları gerek ise düşünebilen cihazlar oluşturabilmek açısından oldukça önemli bir bilim dalıdır. İnsan beyni gibi hareket eden ve karar verebilen modeller üretebilme düşüncesi insanlar için çok eskiye dayanan bir durumdur. Teknolojinin gelişimi ile değişik düşünce yapıları ile insan beynini modelleme fikri uygulamaya konulmuştur. Yapay zekâ, insan beynini, düşünce yapısını, öğrenme, karar verme gibi yeteneklerini taklit ederek makineler üzerinde modellemeyi sağlamaktadır. Yapay zekâ mantığı üzerinde birçok farklı kavramlardan söz edilebilmektedir. Zeka, klasik mantık, sezgisellik, algoritma, optimizasyon, öğrenme gibi kavramlar bunlara örnek olabilmektedir. Yapay zekânın ne olduğunu ortaya koymak için öncelikle bu kavramların ne olduğunun ortaya konması gerekmektedir. Daha sonrasında ise yapay zekânın temeli anlaşılabilir hale gelir. Bunun nedeni yapay zekânın temelini insan beynini taklit etmesidir [2].

Yapay Zekâ ve Makine öğrenmesi terimleri sıklıkla kullanılmakta ve birbirleriyle karıştırılmaktadır. Makine Öğrenimini Yapay Zekânın bir alt kümesi olarak değerlendirebiliriz. Yapay zekâ tıpkı insanlar gibi davranan bir teknoloji tanımyken, makine öğrenmesi çözümleri verileri bulma amaçlıdır. Bu kendi kendine öğrenme kabiliyetine sahip algoritmalar, makinelerin veri kümelerinden öğrenim yapmasını sağlar ve bir görevin tamamlanmasının yolunu açan bir dizi adımdır. Bu bağlamda makine öğrenmesi teknikleri farkında olmadan hayatımızın her aşamasında kullanılmaya başlanmıştır. Yüz tanıma, konuşma tanıma, istenmeyen e-postaların süzülmesi, kredi risk hesabı, müşteri bölütleme gibi uygulamalar yanında yapay zekâda, robotikte, biyoenformatikte, doğal dil işlemede son yıllarda büyük miktarda veriyi işleyerek bilgi çıkartan yapay öğrenme yöntemleri her gün daha çok öne çıkmaktadır [3].

Makine öğrenmesi, bir problemi o probleme ait veriye göre modelleyen bilgisayar algoritmalarının genel adıdır. Mevcut veri seti ve kullanılan algoritma ile oluşturulan model,


en yüksek performansı vermek üzere kurulmaktadır. Bu sebeple pek çok makine öğrenmesi yöntemi geliştirilmiş olup bunlardan bazıları; k-en yakın komşu algoritması, basit (naive) Bayes sınıflandırıcı, karar ağaçları, lojistik regresyon analizi, k-ortalamlar algoritması, destek vektör makineleri ve yapay sinir ağlarıdır. Bu yaklaşımların bir kısmı tahmin ve kestirim, bir kısmı kümeleme ve bir kısmı da sınıflandırma yapabilme yeteneğine sahiptir [4].



Şekil 2.1 Makine öğrenmesi çalışma prensibi.

2.1. Makine Öğrenmesi Türleri

Makine öğrenmesi türleri; Denetimli Öğrenme (Supervised Learning), Denetimsiz Öğrenme (Unsupervised Learning) ve Pekiştirmeli Öğrenme (Reinforcement Learning) olmak üzere genel olarak üç grupta incelenmektedir.



Şekil 2.2 Makine öğrenmesi türleri.

2.1.1. Denetimli öğrenme (Supervised Learning)

Denetimli Öğrenmenin temel ilkesi bildiğimiz örnekleri kullanarak verileri eğitmektir. Örneğin meyve resimleri olan bir kütüphanede bu işlemi yapabiliriz. Muz ve çileklerden oluşan bir kütüphanede önce muz resimlerini belirleyerek etiketliyoruz. Bu resimlere eğitim verisi diyoruz. Daha sonra aynı işlemi çilek bulunan resimler içinde yapıyoruz. Bu resimlerde eğitim verisidir. Daha sonra bir ağda veya büyük veriler üzerinde bulunan fotoğrafları test verisi olarak kullanıyoruz. Fotoğrafların içerisinde bulunan muz ve çilek resimlerini belirtmiyoruz. Bu test verisi ile sistemimizi test ediyoruz. Daha önce belirlediğimiz eğitim verileri sayesinde fotoğraflar içerisinde bulunan muz ve çilek resimlerini sistem tahmin edebiliyor. Fotoğraflarda muz veya çilek ya da her ikisinin birden bulunduğu fotoğrafları bu sayede çıkarabiliriz. Örneğin aşağıdaki Şekil 2.3'de 1 de bulunan meyve sepeti üzerinde muz ve çileği 2 de bulunan muz ve 3 de bulunan çilek fotoğraflarını diğer meyvelerden ayrılabiliriz. Bir eğitim veri seti ile eğitilen makine öğrenmesi yöntemine denetimli öğrenme yöntemi denilmektedir. Basit bir örnekleme ile bu şekilde denetimli öğrenmeyi (Supervised Learning) açıklayabiliriz.



Şekil 2.3 Denetimli öğrenme örneği.

2.1.2. Denetimsiz öğrenme (Unsupervised Learning)

Denetimsiz öğrenmede denetimli öğrenme türünden farklı olarak verileri etiketleyerek eğitim verisi haline getirilerek eğitim yapılmaz. Denetimsiz öğrenme tekniği, eğitilmemiş verileri alarak veride kalıp bulmaya çalışır. Veriler arasında bağlantıları bularak birbirine yakın verileri kümelemeye çalışır. Kümeleme yaparak gruplara ayırabilir.

Denetimsiz öğrenmeye örnek vermek gerekirse. Bir pastane işletmesini örnek olarak inceleyelim. Pastaneye gelen müşterilerin ürün alırken tutum ve davranışlarını inceleyerek buna göre ürün vitrinini düzenlemek ayrıca ürün alımına göre bir sonraki günlerde imalathaneden istenecek ürünler belirlenebilir. Her gün pastaneye gelen müşterilerin gün içerisindeki geliş saatleri ve ürünleri alma durumuna göre gruplandırma yaparak kümeleyerek hem ürün vitrini düzenlenebilir hem de daha sonra gelecek ürünler önceden planlanabilir. Günün saatlerine göre gelen müşterilerin alışveriş alışkanlıklarına göre müşterileri gruplandırılabilir. Bu tür durumlarda denetimsiz algoritma en uygun yöntemdir. Denetimsiz öğrenmede en belirgin durum denetimli öğrenme gibi önceden veri eğitilmemektedir. Duruma göre gruplandırma veya kümeleme yapılır. Denetimsiz öğrenmeye ikinci bir örnek olarak da bir ayakkabı işletmesini verebiliriz. Ayakkabı mağazasına gelen müşteri portföyünde bulunan kişilerin kadın ve erkek oldukları ayrıca kişilerin ayakkabı numaraları önceki yıllardan bilinmektedir. Buna göre mağazaya alınan ayakkabıların kadın ve erkek çeşitlerini ve numaraların gruplandırılması da bu tür algoritmalarla yapılabilir.


2.1.3. Pekiştirmeli Öğrenme (Reinforcement Learning)

Pekiştirmeli Öğrenme diğer bir adıyla takviyeli öğrenmedir. Basitçe insanları taklit etmektedir. Pekiştirmeli Öğrenme diğer makine öğrenme türlerinden farklı olarak ön bilgiye sahip olmadan yani eğitim verisinin olmadığı durumlarda kullanılır. İnsanlar doğduklarından itibaren kazandıkları tecrübe ve bilgilerden öğrenim kazanırlar. Bir bebeğin düştüğü zaman dizinin acıması ve düşmenin hatalı bir durum olduğunu bilmesi ona başkası tarafından öğretilmeden kendi tecrübesi ve yaşadığı ile ilgili bir öğrenme şeklidir. Yaşadığı ortam yani çevre ile etkileşime girerek yaptıklarını gözlemleyerek öğrenir. Pekiştirmeli öğrenmede bu yaklaşımdan hareketle çalışmaktadır. Pekiştirmeli öğrenmede ödül ve ceza kavramı vardır. Ödül ve ceza pekiştirmeli öğrenmede yazılımın başarısını artıran bir algoritmadır. Makine tarafından yapılan başarılı işler artı puan alırken başarısız işlerde de eksi puan verilir. Bu şekilde makine kendinin daha fazla artı işler yapmaya hedefleyerek öğrenir.

Pekiştirmeli Öğrenme bir sistemi kontrol etmeyi öğrenmekle ilgili bir öğrenmedir. Bir hedefe varmak için gereken bir sayısal ölçüyü maksimuma çıkarmak ile ilgilenir. Pekiştirmeli Öğrenme bulunduğu ortamı algılayan ve kendi başına kararlar alabilen bir sistemin hedefine ulaşabilmesinde doğru kararlar almayı nasıl öğrenebileceğini gösterir. Pekiştirmeli öğrenmede sistemin çıktı değerlerinin iyi veya kötü olup olmadığına dair bilgi verilir. Takviyeli öğrenmede bir eğitmen bulunur. Denetimli öğrenmedeki gibi sisteme çok bilgi vermez veya veremez. Ödül ve Ceza Sinyalleri vardır. Sistem bir karar verdiğinde bu kararın doğru olduğu durumlar için sistemi ödüllendirir ve yanlışlar için de cezalandırır [5].

Pekiştirmeli öğrenmede çevre faktöründen bahsettik. Mesela hava durumuna göre trafiğin nasıl olacağı makine tarafından yorumlanırken yağmurlu havada trafiğin yoğun, normal havada daha az yoğun olacağının belirlenmesi örnek verilebilir.

Pekiştirmeli öğrenme açıklanırken bazı kavramlar belirlenmiştir. Bunlar ajan ve çevre etkileşimi ile oluşmuştur. Ajan ile çevre arasındaki etkileşim sonucunda eylem, durum, amaç, ödül ve davranış adında oluşan terimler problemlerin çözümünde kullanılacak terimlerdir. Aşağıdaki şekilde terimler arasındaki durumlar ifade edilmiştir [6].



Şekil 2.4 Pekiştirmeli öğrenme şeması.

2.2. Makine öğrenmesi uygulamaları

Makine öğrenmesi uygulamaları son yıllarda hayatımızın merkezine yerleşmiştir. Günlük işlevlerimizi gerçekleştirirken artık bunlara ihtiyaç duymaya başlamış bulunuyoruz. Her gün yanımızdan ayırmadığımız cep telefonları üzerinde yer alan Siri, Alexa, Google asistan gibi popüler uygulamalar danıştığımız asistan gibi sürekli kullandığımız uygulamalardır. İşe giderken hangi yolu kullanacağımız ve ne kadar sürede gideceğimiz bilgisini bize veren yandex ve google harita gibi GPRS (General Packet Radio Service) tabanlı bizim verilerimizi kullanarak bize kolaylık sağlayan uygulamalardır. UBER gibi taksi sisteminde gideceğimiz yere ne kadar ücret ödeyeceğimizi tespit ederken de makine öğrenmesi kullanılmaktadır. Sosyal medya hesaplarımızı kullanırken karşımıza çıkan reklamlar veya tanıdığımız kişilerin karşımıza çıkması da makine öğrenmesine örnek uygulamalardır. Bunlar dışında yüz ve ses tanıma, E-posta spam filitreleme, Chatbot gibi çevrimiçi müşteri desteği ve elektronik ticaret sitelerinde ürün önerme gibi birçok uygulama hayatımızda vazgeçilmez hale gelmiş sürekli kullandığımız makine öğrenmesi uygulamalarıdır [7].

Bir makine öğrenmesi metodu tahminde bulunmak için bir çıktı üretir. Bu çıktı kategorik ise sınıflandırma (classification) ve eğer nümerik ise regresyon (regression) denir. Açıklayıcı bir modelleme olan kümeleme (Clustering) ise benzer gözlemleri aynı kümelere atama işlemidir. Birliktelik Kuralları (Association Rules) ile gözlemler arasındaki ilginç bağlantılar bulunabilir. Sınıflandırma ve regresyon yöntemleri eğitim verisine ihtiyaç duyduğu için Denetimli (supervised) öğrenme olarak anlatılırken diğer iki metot eğitim verisi gerektirmediği için Denetimsiz (unsupervised) öğrenme olarak adlandırılır [8].


2.2.1. Sınıflandırma (Classification)

Makine Öğrenmesi ve istatistik biliminde sınıflandırmayı tanımlayacak olursak bilgisayar programının kendisine girilen veri girişinden öğrendiği ve daha sonra yeni gözlemleri sınıflandırmak için bu öğrenmeyi kullandığı denetimli bir öğrenme yaklaşımıdır. Bu veri seti basitçe iki sınıf olabilir (kişinin erkek mi kadın mı olduğu, postanın spam mı yoksa spam olmayan mı olduğu gibi) veya çok sınıflı da olabilir. Bazı sınıflandırma problemleri örnekleri: konuşma tanıma, el yazısı tanıma, biyometrik tanımlama, doküman sınıflandırma vb. [9] Sınıflandırma problemlerinde çıktı uzayındaki her bir eleman birer sınıf (class), sınıflandırma problemini çözen algoritmaya da sınıflandırıcı (classifier) adı verilmektedir [10]. Literatürde makine öğrenmesinde sınıflandırma için kullanılan Karar Ağaçları, NaiveBayes Sınıflandırıcı, Yapay Sinir Ağları, Destek Vektör Makineleri, k-En Yakın Komşu Algoritması gibi çok sayıda algoritma mevcuttur sınıflandırma algoritmalarında, var olan verilerden örüntü keşfedilir ve yeni eklenecek nesnelerin hangi sınıfta yer alacağı tahmin edilir[11].

Veriler arasında karmaşıklığı basitleştirmek için sınıflandırma yöntemi kullanılır. Verilerin sınıflandırılması için belirli bir süreç işlenir. Öncelikle var olan verinin bir kısmı eğitim amacıyla kullanılarak sınıflandırma kurallarının oluşması sağlanır. Daha sonra bu kurallar yardımıyla yeni bir durum ortaya çıktığında nasıl karar verileceği belirlenir [12].

Makine öğrenmesinde sınıflandırma algoritmaları veri seti olarak öğrenme programına sunulan sınıf etiketli örnekleri kullanarak tanım alanına yönelik örüntüleri öğrenir. Sınıflandırma örneklerden çıkarım olarak da tarif edilir. Sınıflandırmada genel amaç kavram tanımlı elde edildikten sonra daha önce algoritmaya tanıtılmamış örnekleri en yüksek doğrulukta etiketleyecek sınıflandırıcıyı geliştirmektir [13].


Aşağıdaki grafikte görüldüğü gibi farklı veri türlerini birbirinden ayırmak için bu veri türleri arasına sınırlar konulmuştur. Hedef sınıfı diğer sınıflardan ayırt etmek için kullanılır.Amaç hata oranını en aza indirmektir [14].



Şekil 2.5 Sınıflandırma sınırları örneği.

2.2.2. Kümeleme (Clustering)

Denetimsiz öğrenmeyi baz alan kümelemede amaç veri kümesi içerisindeki veri örneklerini sadece özellik (feature) vektörlerine göre gruplamaktır. Bunun için örneklerin birbirine benzerliği gözetilir. Kümeleme literatüründe benzerlik terimi uzaklık terimiyle zıt anlamda kullanılmaktadır. Birbirine benzer olan örnekler aynı kümeye ve biri birinden uzak olan örnekler farklı kümeler yerleştirilmeye çalışılır. Küme sayısı genellikle dışarıdan verilir [15]. Kümeleme verilerin kendi aralarındaki benzerliklerin kullanılarak gruplandırılması genel amaçtır. Bu özellik nedeniyle pek çok alanda kümeleme kullanılmaktadır. Örneğin Pazar araştırmalarında, desen tanımlamada, resim ve görüntü işleme ve uzaysal verilerin analizinde kullanılmaktadır [12]. Kümeleme ile sınıflandırmanın bir birinden farkı makine öğrenmesi türlerinin farklı olmasıdır. Sınıflandırma denetimli öğrenme kümeleme ise denetimsiz öğrenmedir. Kümelemede sınıflandırmada olduğu gibi eğitim ve test verisi yoktur. Temel amaç verileri gruplandırmaktır. K-Means ve Hiyerarşik Bölütleme yaygın olarak kullanılan kümeleme algoritmalarındandır [16]. Aşağıdaki şekilde kümeleme işlemi resimler örneklenmiştir.



Şekil 2.6 Kümele işlemi örneği.

Kümelemede önemli olan veriler arasında benzerliğin nasıl belirleneceğidir. Veriler arasında benzerliği ve farklılığı ölçmek için genellikle Öklid, Manhattan ve Minkowski gibi bir uzaklık ölçüsü kullanılır. Veriler arasındaki mesafeyi belirtmek için $dist(x_i, x_j)$ kullanırız. Kümele Yöntemlerinde kullanılan uzaklık formülleri aşağıda verilmektedir [17].

$$dist(x_i, x_j) = \sqrt{(x_{i1} - x_{j1})^2 + (x_{i2} - x_{j2})^2 + \dots + (x_{ir} - x_{jr})^2} \quad (2.1)$$

Öklid mesafesi.

$$dist(x_i, x_j) = |x_{i1} - x_{j1}| + |x_{i2} - x_{j2}| + \dots + |x_{ir} - x_{jr}| \quad (2.2)$$

Manhattan mesafesi.

$$dist(x_i, x_j) = (|x_{i1} - x_{j1}|^h + |x_{i2} - x_{j2}|^h + \dots + |x_{ir} - x_{jr}|^h)^{\frac{1}{h}} \quad (2.3)$$

Minkowski mesafesi.

2.2.3. Birliktelik Kuralları (Association Rules)

Birliktelik Kuralları verilerin birbirleriyle olan ilişkilerini inceleyerek, hangi olayların eşzamanlı olarak birlikte gerçekleştirilebileceklerini ve aralarındaki ilişkinin büyüklüğünü ortaya koymaya çalışan yöntemin adıdır. Örneğin bir markete gelen müşterilerin aldığı ürünler incelenerek rafların tasarımı bu algoritmalar sayesinde yapılabilir. Alışveriş esnasında hangi ürünleri aldığı tespit edilip en çok birlikte alınan ürünler yakın raflara yerleştirilebilir. Bu tür uygulamalar özellikle pazarlama sektöründe yer bulmuştur. “Pazar sepet Analizi” adı verilen bu yöntemlerle müşterilerin alışveriş alışkanlıkları belirlenmeye çalışılmaktadır [12]. Eğer elimizdeki veride mallar için sadece satın alındı/alınmadı bilgisi varsa, sepet analizinde

mallar arasındaki bağıntı, destek ve güven kıstasları aracılığıyla hesaplanır. X ve Y gibi iki mal için destek (support) ve güven (confidence) tanımları şöyledir:

Destek: $P(X \text{ ve } Y) = X \text{ ve } Y \text{ mallarını satın almış müşteri sayısı} / \text{Toplam müşteri sayısı}$

Güven: $P(X|Y) = P(X \text{ ve } Y) / P(Y)$
 $= X \text{ ve } Y \text{ mallarını satın almış müşteri sayısı} / Y \text{ malını satın almış müşteri sayısı}$

Destek veride bu bağıntının ne kadar sık olduğunu, güven de Y malını almış bir kişinin hangi olasılıkla X malını alacağını söyler. Bağıntının önemli olması için her iki değerin de olabildiğince büyük olması gerekir [18].

2.3. Denetimli Öğrenme Algoritmaları

Bölüm 2.1.1. de Denetimli Öğrenmenin tanımını yapmıştık. Denetimli öğrenmede sınıflandırma işlemi uygulanmaktadır. Denetimli öğrenme yönteminde kategori yapısının ve verilerin hiyerarşik düzeninin önceden bilindiği varsayılır. Öncelikle etiketlenmiş bir eğitim setine ihtiyaç vardır. Bu veri seti üzerinden çeşitli öğrenme algoritmaları kullanılıp bilinen sınıf etiketleri ile eşleştirme yapılır. Daha sonra, değişik veri setleri kullanılarak bu eşleşmenin başarısı ölçülmeye çalışılır. Denetim öğrenme algoritmalarından başlıcaları şunlardır. K- Komşu algoritması, Karar Ağaçları, NaiveBayes Sınıflandırıcı, Bayesien, Destek Vektör Makinesi ve Yapay Sinir Ağları algoritmalarıdır [19].

2.3.1. Sınıflandırma Modeli Elde Etme Süreci

Sınıflandırma modeli elde etme iki aşamalı bir süreçtir [20,12]. Birinci aşamada model oluşturmak için eğitim verisi seçilir. Rastgele veriler içerisinde eğitim verisi yapılmak üzere veri belirlenir. Daha sonra eğitim verisi üzerinde elde edilen model test verisine uygulanır.