

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/366393880>

# Zaman serisi analizi ile talep tahmini ve bir fabrikadaki üretim planlama

Chapter · December 2022

CITATIONS

3

READS

789

1 author:



Burak Gülmez

Mudanya University

24 PUBLICATIONS 316 CITATIONS

SEE PROFILE

# **ZAMAN SERİSİ ANALİZİ İLE TALEP TAHMİNİ VE BİR FABRİKADAKİ ÜRETİM PLANLAMA**

Burak GÜLMEZ<sup>1</sup>

---

## **GİRİŞ**

Tahmin, uzun vadeli stratejik planlamaya rehberlik eden ve üretim, nakliye, personel, iş planlama ve çizelgelemeleriyle ilgili yol gösterici bir istatistiksel çalışmadır. Bununla birlikte, tahmin sıklıkla planlama ve hedeflerle karıştırılır. Bu kavramlar birbirlerinden farklı kavramlardır. Tahmin, geçmiş veriler ve olayların bilgisi dahilinde olmak üzere mevcut tüm bilgilerin göz önüne alınarak, geleceği mümkün olduğunca doğru bir şekilde bilme olayıdır. Hedefler, gerçekleşmesi arzu edilen şeylerdir. İdeal olarak, her zaman böyle olmasa da, hedefler tahminlere ve planlara bağlanmalıdır. Çok sık olarak, hedefler, onlara nasıl ulaşılabileceğine dair bir strateji veya fizibilitelerinin bir değerlendirmesi olmaksızın belirtilir. Planlama, tahminlere ve hedeflere göre alınan reaksiyonlardır. Planlama, tahminleri hedeflerle uyumlu

---

<sup>1</sup> Arş. Gör. Dr., Erciyes Üniversitesi, <https://orcid.org/0000-0002-6870-6558>, [burakgulmez@erciyes.edu.tr](mailto:burakgulmez@erciyes.edu.tr)

hale getirmek için gerekli adımları belirlemektir. Tahmin, bir işletmenin birçok yönü üzerinde önemli bir etkiye sahip olabileceğinden, yönetimin karar verme süreçlerinin temel bir unsuru olmalıdır. Uygulamaya bağlı olarak, modern kuruluşlar kısa vadeli, orta vadeli ve uzun vadeli projeksiyonlar talep eder. Personel, üretim ve nakliye planlaması kısa vadeli projeksiyonlara ihtiyaç duyar. Talep tahminleri genellikle planlama sürecinin bir parçası olarak gereklidir. Hammaddede satın almak, personel istihdam etmek veya makine ve ekipman satın almak için gelecekteki kaynak ihtiyaçlarını tahmin etmek için orta vadeli projeksiyonlar gereklidir. Stratejik planlama, uzun vadeli tahminler kullanır. Bu seçimler pazar fırsatlarını, çevresel hususları ve iç kaynakları dikkate alınmalıdır. Bir şirket, öngörülemeyen olayları tahmin etmek için birçok yöntem kullanan bir tahmin sistemi tasarlamalıdır. Bu tür tahmin sistemleri, tahmin konularının tanımlanması, çeşitli tahmin tekniklerinin uygulanması, her problem için uygun yöntemlerin seçilmesi ve tahmin yöntemlerinin zaman içinde değerlendirilmesi ve iyileştirilmesi konularında uzmanlığın geliştirilmesini gerektirir. Resmi tahmin tekniklerinin etkili bir şekilde kullanılması gerekiyorsa, kullanımları için güçlü bir organizasyonel desteğe sahip olmak da aynı derecede önemlidir (Gülmez, 2021; Hyndman & Athanasopoulos, 2018; Şen, 2020).

Bir tahmin projesinin ilk aşamalarında, neyin tahmin edilmesi gerektiğine dair kararlar alınması gerekir. Örneğin, bir üretim ortamındaki kalemler için tahminler gerekiyorsa, aşağıdakiler için tahminlerin gerekli olup olmadığını sormak gerekir (Hyndman & Athanasopoulos, 2018):

- Her ürün grubu için mi yoksa ürün grupları için mi?
- Her satış noktası için mi yoksa bölgeye göre gruplandırılmış satış noktaları için mi yoksa yalnızca toplam satışlar için mi?
- Haftalık veri mi, aylık veri mi, yıllık veri mi?
- Tahmin ufkunu da dikkate almak gereklidir. Tahminler bir ay için mi, altı ay için mi yoksa beş yıl için mi gerekli olacak? Hangi tahmin ufkunun en önemli olduğuna bağlı olarak farklı model türleri gerekli olacaktır.
- Tahminler ne sıklıkla gereklidir? Sık sık üretilmesi gereken tahminler için manuel çalışma gerektiren yöntemlerdense otomatik bir sistem kullanmak daha iyidir.

Hangi tahminlerin gerekli olduğu belirlendikten sonra, tahminlerin dayanacağı verilerin bulunması veya toplanması gerekir. Tahmin için gerekli veriler zaten mevcut olabilir. Günümüzde pek çok veri kaydediliyor ve veri ile uğraşan kişinin görevi genellikle gerekli verilerin nerede ve nasıl saklandığını belirlemektir. Veriler, bir şirketin satış kayıtlarını, bir ürüne yönelik tarihsel talebi veya bir coğrafi bölge için işsizlik oranını içerebilir. Bir veri bilimcisinin zamanının büyük bir kısmı, uygun tahmin yöntemlerini geliştirmeden önce mevcut verileri bulmak ve onlar üzerinde işlemler yapmak için harcanabilir. Tahminleme genellikle beş temel adımı içerir (Hyndman & Athanasopoulos, 2018; Karakoyun, 2018):

Birinci adım problem tanıımıdır. Problemi dikkatli bir şekilde tanımlamak, tahminlerin nasıl kullanılacağını, tahminleri kimin gerektirdiğini ve tahmin fonksiyonunun

tahminlere ihtiyaç duyan organizasyona nasıl uyduğunu anlamayı gerektirir.

İkinci adım bilgi toplamadır. Bu bilgiler hem istatistiksel verilerden oluşur hem de verileri toplayan kişinin bilgi birikimidir. Genellikle, iyi bir istatistiksel modele uyması için yeterli tarihsel veriyi elde etmek zor olacaktır. Bazen, tahmin edilen sistemdeki yapısal değişiklikler nedeniyle eski veriler işe yaramaz olabilir. Böyle durumlarda sadece en son verileri kullanmak seçilebilir. Ancak, iyi istatistiksel modeller sistemdeki değişiklikleri de algılar, bundan dolayı verileri gereksiz yere atmamak gerekir.

Üçüncü adım veriyi keşfetmektir. Bunun için veriler grafik haline getirilebilir. Tutarlı modeller var mı? Önemli bir eğilim var mı? Mevsimsellik önemli mi? İş çevrimlerinin varlığına dair kanıt var mı? Verilerde uzman bilgisine sahip kişiler tarafından açıklanması gereken herhangi bir aykırı değer var mı? Analiz için mevcut değişkenler arasındaki ilişkiler ne kadar güçlü? Bu ve bunun gibi analizlerle veri keşfedilir ve gerekliyse bazı işlemler gerçekleştirilir.

Dördüncü adım model seçimidir. Kullanılacak en iyi model, tarihsel verilerin mevcudiyetine, tahmin değişkeni ile herhangi bir açıklayıcı değişken arasındaki ilişkilerin gücüne ve tahminlerin nasıl kullanılacağına bağlıdır. Sadece bir model üzerinden gidilmemelidir. En azından birkaç model denenmelidir. Her modelin kendisi, bir dizi varsayıma dayanan bir yapıdır ve genellikle bilinen tarihsel veriler kullanılarak tahmin edilmesi gereken bir veya daha fazla parametre içerir.

Beşinci adım tahmin modelinin kullanılması ve değerlendirilmesidir. Bir model seçildikten ve parametreleri denendikten sonra, model tahmin yapmak için kullanılır. Modelin performansı, ancak tahmin dönemi verileri kullanılabilir hale geldikten sonra uygun şekilde değerlendirilebilir. Tahminlerin doğruluğunun değerlendirilmesi için gerçek değerlerle karşılaştırılır ve performans değerlendirmesi için kullanılır.

### **LİTERATÜR TARAMASI**

Literatürde zaman serileri oldukça çok sayıda çalışma içermektedir. Üretim planlama, üretim tahmini, talep tahmini gibi durumlar için zaman serileri yöntemleri kullanılmaktadır. Zaman serileri sadece bu alanlarda değil farklı alanlarda da kullanılmaktadır.

Ayoobi vd. (2021) zaman serisi analizini yeni COVID-19 vakalarını ve ölümlerini tahmin etmek için kullanmıştır. Yöntem olarak ise derin öğrenme yöntemini denemiştir. Talkhi vd. (2021) benzer şekilde İran'daki COVID-19 vaka ve ölüm sayılarını ARIMA, yapay sinir ağları gibi yöntemlerle tahmin etmeye çalışmışlardır. Bi vd. (2021) derin öğrenme ile zaman serisi analizini turizm verileri üzerinde test etmişlerdir. Geleceğe yönelik turist sayısı tahmini gerçekleştirmişlerdir. Kim ve Kim (2021) elektrikli araç kullanımına bağlı olarak elektrikli şarj istasyonlarına olan talebin artacağından bahsetmiştir. Bunun için şarj istasyonlarına oluşacak talebi tahmin etmeye çalışmıştır. ARIMA, YSA gibi yöntemleri kullanmışlardır. Cheng vd. (2021) hastanelerdeki acil servisler için bir zaman serisi çalışması üzerinde çalışmışlardır. Saatlik olarak veriyi düşünmüşlerdir ve bundan dolayı SARIMA kullanmışlardır. Alduailij

vd. (2021) akıllı binalar için en yüksek enerjiye ihtiyaç duyulan anları ve bu anlardaki enerji ihtiyaçlarını zaman serisi analizi ile tespit etmişlerdir. Çalışmalarında ARIMA kullanmışlardır. Bu çalışmalara benzer şekilde çok sayıda farklı alanlarda çalışmalar mevcuttur (Di Piazza vd., 2021; Dittmer vd., 2021; Gijon vd., 2021; Rožanec vd., 2022).

## **YÖNTEM**

Zaman serisi analizi için farklı algoritmalar mevcuttur. Genelde ARIMA ve SARIMA ile zaman serileri yapılmaktadır. Bunların yanı sıra yapay sinir ağları da sıkça kullanılmaktadır.

### **Bütünleşik Otoregresif Hareketli Ortalama (ARIMA)**

Otoregresyon ile hareketli ortalama modellerinin birleşiminden oluşmaktadır. İçerisinde mevsimsellik yoktur. ARIMA modelleri  $p$ ,  $d$  ve  $q$  olmak üzere üç adet parametreye sahiptir.  $p$ , otoregresif bölümün sırasını,  $d$ , birinci farkın derecesini,  $q$ , hareketli ortalamanın sırasını temsil etmektedir (Piccolo, 1990).


### **Mevsimsel Otoregresif Hareketli Ortalama (SARIMA)**

ARIMA modelleri dönemden, aydan, mevsimden arındırılmış modellerdir. Fakat bazı durumlarda mevsimsellik oldukça önemlidir ve gelecek tahminlerinde oldukça önemli rol oynamaktadır. ARIMA modeline mevsimsellik eklenmiş hali SARIMA modelidir. ARIMA'da bulunan  $p$ ,  $d$ ,  $q$  parametrelerinin yanı sıra mevsimselliği temsil eden  $P$ ,  $D$ ,  $Q$  parametrelerine de sahiptir (Valipour, 2015).

### Yapay Sinir Ağları (YSA)

YSA insan beyninin çalışma sisteminden etkilenecek geliştirilmiştir. İnsanın geçmiş tecrübelerinden yola çıkarak elde ettiği zekayı taklit etmektedir. İnsan beyninde nöronlar vardır. Nöronlar sinir hücrelerine verilen addır. Nöronlar kendi aralarında bağlantılar kurarlar. Kurdukları bağlantılar sayesinde iletişim gerçekleştirirler ve bilgi iletimini sağlarlar.

Yapay sinir ağları insandaki nöronlar ile benzerlik gösterir. Yapay sinir ağının yapısı Şekil 1'deki gibidir. Şekilde görüldüğü üzere YSA üç katmandan oluşmaktadır. Birinci olarak girdi katmanı vardır. Girdi katmanında girdi değerleri yer almaktadır. Girdi katmanından sonra gizli katmanlar vardır. Gizli katmanlar girdi katmanı ile çıktı katmanını birbirine bağlar. Üçüncü olarak ise çıktı katmanı vardır. Çıktı katmanı sonucu verir.



Şekil 1: Yapay Sinir Ağı Yapısı (Gülmez & Kulluk, 2019)



Buradaki problem için YSA özelleştirildiğinde girdi katmanında geçmişteki üretim miktarlarını karşılayacak kadar sayıda nöron bulunmalıdır. Aradaki gizli katmanlar sayıca farklılık gösterebilir. Çıktı katmanı ise tahmin içereceği için tek bir nörondan oluşmalıdır. Tasarlanacak YSA yapısı çözüm kalitesinde önemli bir rol oynayacaktır. Genellikle sadece bir adet gizli katman bulunan YSA'lar basit kalabilmektedir. Birden fazla gizli katmana sahip YSA'lar daha kompleks ve karmaşık problemleri çözebilmektedir. Birden fazla gizli katmanlı YSA yöntemine derin öğrenme de denmektedir.

### BULGULAR

Bu problemde zaman serileri analizi ile bir fabrikadaki üretim miktarları tahmin edilmeye çalışılmıştır. Üretim tahmini için kullanılabilecek farklı algoritmalar mevcuttur. Bu algoritmalar test edilmiş ve karşılaştırılmıştır. Öncelikle bu fabrikada üretilen ürün miktarı için geçmiş veriler iki farklı kümeye bölünecektir. Bu kümelerden ilki eğitim verisi olarak kullanılacaktır. Diğer veri kümesi ise test verisi olarak kullanılacaktır. Böylece algoritmaların gerçekteki kaliteleri ortaya çıkacaktır.


Algoritmaların karşılaştırılmaları ve performans değerlendirmeleri için hata kareleri toplamları (mean squared error), (mean absolute percentage error) ve (mean absolute error) yöntemleri kullanılacaktır. Bu yöntemlerin formülleri (1), (2) ve 3'te verilmiştir.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (1)$$


$$MAPE = \frac{100}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i} \quad (2)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (3)$$


Veri üç farklı ürün için sipariş miktarlarını içermektedir. Bu ürünler A, B ve C isimleri ile temsil edilmiştir. Kullanılan veri günlük toplam sipariş sayıdır. Veriler sırasıyla Şekil 2, Şekil 3 ve Şekil 4'te gösterilmiştir.



Şekil 2: A Ürünü İçin Yıllık Talep Miktarı




Şekil 3: B Ürünü İçin Yıllık Talep Miktarı



Şekil 4: C Ürünü İçin Yıllık Talep Miktarı

Veri bütünleşik otoregresif hareketli ortalama (ARIMA) modeliyle test edilmiştir. A ürünü için eğitim verileri, test verileri ve yapılan tahminler Şekil 5'de görülebilir.




**Şekil 5:** A Ürünü İçin ARIMA ile Yapılan Tahmin Grafiği

ARIMA ile A ürünü tahmininde MSE değeri 88.709, MAPE değeri 3.004 ve MAE değeri 7.494 çıkmıştır. Sonuçlar Tablo 1’de görülebilir.

**Tablo 1:** A Ürünü İçin ARIMA ile Yapılan Tahmin Sonuçları

| A ürünü | MSE    | MAPE  | MAE   |
|---------|--------|-------|-------|
| ARIMA   | 88.709 | 3.004 | 7.494 |

ARIMA ile B ürünü için eğitim verileri, test verileri ve yapılan tahminler Şekil 6’da görülebilir.




**Şekil 6:** B Ürünü İçin ARIMA ile Yapılan Tahmin Grafiği

ARIMA ile B ürünü tahmininde MSE değeri 29.671, MAPE değeri 1.718 ve MAE değeri 4.746 çıkmıştır. Sonuçlar Tablo 2’de görülebilir.

**Tablo 2:** B Ürünü İçin ARIMA ile Yapılan Tahmin Sonuçları

| B ürünü | MSE    | MAPE  | MAE   |
|---------|--------|-------|-------|
| ARIMA   | 29.671 | 1.718 | 4.746 |

ARIMA ile C ürünü için eğitim verileri, test verileri ve yapılan tahminler Şekil 7’de görülebilir.




**Şekil 7:** C Ürünü İçin ARIMA ile Yapılan Tahmin Grafiği

ARIMA ile C ürünü tahmininde MSE değeri 291.569, MAPE değeri 0.912 ve MAE değeri 14.457 çıkmıştır. Sonuçlar Tablo 3’de görülebilir.

**Tablo 3:** C Ürünü İçin ARIMA ile Yapılan Tahmin Sonuçları

| C ürünü | MSE     | MAPE  | MAE    |
|---------|---------|-------|--------|
| ARIMA   | 291.569 | 0.912 | 14.457 |

Veri mevsimsel otoregresif hareketli ortalama (SARIMA) modeliyle test edilmiştir. A ürünü için eğitim verileri, test verileri ve yapılan tahminler’ Şekil 8’de görülebilir.




**Şekil 8:** A Ürünü İçin SARIMA ile Yapılan Tahmin Grafiği

SARIMA ile A ürünü tahmininde MSE değeri 74.752, MAPE değeri 2.727 ve MAE değeri 7.113 çıkmıştır. Sonuçlar Tablo 4’de görülebilir.

**Tablo 4:** A Ürünü İçin SARIMA ile Yapılan Tahmin Sonuçları

| A ürünü | MSE    | MAPE  | MAE   |
|---------|--------|-------|-------|
| SARIMA  | 74.752 | 2.727 | 7.113 |

SARIMA ile B ürünü için eğitim verileri, test verileri ve yapılan tahminler Şekil 9’da görülebilir.




**Şekil 9:** B Ürünü İçin SARIMA ile Yapılan Tahmin Grafiği

SARIMA ile B ürünü tahmininde MSE değeri 26.684, MAPE değeri 1.445 ve MAE değeri 4.472 çıkmıştır. Sonuçlar Tablo 5’de görülebilir.

**Tablo 5:** B Ürünü İçin SARIMA ile Yapılan Tahmin Sonuçları

| B ürünü | MSE    | MAPE  | MAE   |
|---------|--------|-------|-------|
| SARIMA  | 26.684 | 1.445 | 4.472 |

SARIMA ile C ürünü için eğitim verileri, test verileri ve yapılan tahminler Şekil 10’da görülebilir.




**Şekil 10:** C Ürünü İçin SARIMA ile Yapılan Tahmin Grafiği

SARIMA ile C ürünü tahmininde MSE değeri 287.177, MAPE değeri 0.905 ve MAE değeri 14.194 çıkmıştır. Sonuçlar’ Tablo 6de görülebilir.

**Tablo 6:** C Ürünü İçin SARIMA ile Yapılan Tahmin Sonuçları

| C ürünü | MSE     | MAPE  | MAE    |
|---------|---------|-------|--------|
| SARIMA  | 287.177 | 0.905 | 14.194 |

Veri YSA ile test edilmiştir. YSA farklı yapılar da tasarlanabilir. YSA’da tek gizli katman olma zorunluluğu yoktur. Birden fazla gizli katman bulunabilir. Birden fazla gizli katman olan YSA’lara derin öğrenme adı verilmektedir. Daha etkili sonuç verdiği için derin öğrenme ile test edilecektir. YSA ile A ürünü için eğitim verileri, test verileri ve yapılan tahminler Şekil 11’da görülebilir.




**Şekil 11:** A Ürünü İçin YSA ile Yapılan Tahmin Grafiği

YSA ile A ürünü tahmininde MSE değeri 63.890, MAPE değeri 0.444 ve MAE değeri 6.756 çıkmıştır. Sonuçlar Tablo 7’de görülebilir.

**Tablo 7:** A Ürünü İçin YSA ile Yapılan Tahmin Sonuçları

| A ürünü | MSE    | MAPE  | MAE   |
|---------|--------|-------|-------|
| YSA     | 63.890 | 0.444 | 6.756 |

YSA ile B ürünü için eğitim verileri, test verileri ve yapılan tahminler Şekil 12’de görülebilir.




**Şekil 12:** B Ürünü İçin YSA ile Yapılan Tahmin Grafiği

YSA ile B ürünü tahmininde MSE değeri 35.819, MAPE değeri 0.939 ve MAE değeri 5.415 çıkmıştır. Sonuçlar Tablo 8’de görülebilir.

**Tablo 8:** B Ürünü İçin YSA ile Yapılan Tahmin Sonuçları

| B ürünü | MSE    | MAPE  | MAE   |
|---------|--------|-------|-------|
| YSA     | 35.819 | 0.939 | 5.415 |

YSA ile C ürünü için eğitim verileri, test verileri ve yapılan tahminler Şekil 13’da görülebilir.



**Şekil 13:** C Ürünü İçin YSA ile Yapılan Tahmin Grafiği

YSA ile C ürünü tahmininde MSE değeri 289.566, MAPE değeri 0.371 ve MAE değeri 14.428 çıkmıştır. Sonuçlar Tablo 9’de görülebilir.

**Tablo 9:** C Ürünü İçin YSA ile Yapılan Tahmin Sonuçları

| C ürünü | MSE     | MAPE  | MAE    |
|---------|---------|-------|--------|
| YSA     | 289.566 | 0.371 | 14.428 |

## TARTIŞMA

Tüm algoritmaların ve değerlendirme kriterlerinin yer aldığı özet tablo Tablo 10’da gösterilmiştir. Özet tabloya bakıldığında SARIMA ve YSA’nın ARIMA’ya göre daha başarılı tahminler yürüttüğü görülmüştür.

**Tablo 10:** Özet Tablo

| Yöntem | Ürün | MSE     | MAPE  | MAE    |
|--------|------|---------|-------|--------|
| ARIMA  | A    | 88.709  | 3.004 | 7.494  |
|        | B    | 29.671  | 1.718 | 4.746  |
|        | C    | 291.569 | 0.912 | 14.457 |
| SARIMA | A    | 74.752  | 2.727 | 7.113  |
|        | B    | 26.684  | 1.445 | 4.472  |
|        | C    | 287.177 | 0.905 | 14.194 |
| YSA    | A    | 63.890  | 0.444 | 6.756  |
|        | B    | 35.819  | 0.939 | 5.415  |
|        | C    | 289.566 | 0.371 | 14.428 |

Zaman serisi analizi bir fabrikadaki A, B ve C ürünlerinin talep tahmini için kullanıldığında talep verilerinin çok düzenli olmadığı görülmüştür. Veriler çok dalgalıdır. A, B ve C ürünlerinin talep tahminlerini gerçekleştirmek için ARIMA, SARIMA ve YSA yöntemleri kullanıldığında SARIMA ve YSA yöntemlerinin ARIMA yöntemine nazaran daha başarılı çıktıkları görülmektedir. Bunun bir sebebi SARIMA, ARIMA'ya göre içerisinde mevsimsel değişiklikleri de barındırır. Bu sayede daha başarılı sonuçlar verir. YSA ise ARIMA ve SARIMA'dan çok farklı bir yöntemdir ve her alanda uygulanabilir. Son derece esnektir ve gelişmiştir. Bundan dolayı YSA da iyi sonuçlar vermiştir. Fabrikadaki üretim planlaması yapılırken SARIMA veya YSA sonuçları dikkate alınmalıdır. Fabrikadaki üretim planlama için güvenlik stoğu, üretim süresi, siparişin ulaşma süresi gibi değişkenler göz önünde bulundurulduğunda çok kritik bir şekilde doğru tahminde bulunmak önemlidir. Bu çalışmada gelecek için SARIMA ve YSA tahminlerinin ortalamasının alınması üretim planlama için önerilmiştir.



## **SONUÇ VE ÖNERİLER**

Zaman serisi analizi çok farklı alanlarda kullanımı olan bir problem türüdür. Buradaki amaç geçmiş bilgilerden geleceğe dönük tahminler yapmaktır. Geleceğe dönük yapılan tahminler için geçmiş veriler kullanılmaktadır ve bu verilerin içinde trend, mevsimsellik gibi farklı etkiler bulunabilir. Bu etkileri kavrayıp gelecek için en başarılı tahmini bulmak asıl amaçtır. Bu çalışmada bir fabrikadaki üretim hattındaki üretim planlamaları yapmak için geçmiş taleplere bağlı olarak bir üretim planlaması çıkarmak amaçlanmaktadır. Bunun için iyi bir tahmin gerekmektedir. Geçmişteki üç ürünün talep değerleri kullanılarak gelecek tahminleri yapılmıştır. Bu tahminler için üç farklı algoritma denenmiştir. Bunlar ARIMA, SARIMA ve YSA yöntemleridir. SARIMA ve YSA başarılı çıkmıştır. Bundan dolayı SARIMA ve YSA sonuçlarının ortalamasına göre bir üretim planlama yapılması önerilmektedir. Gelecekteki çalışmalarda YSA üzerinde parametre optimizasyonu gibi geliştirmeler uygulanması önerilmektedir. Ve bu sayede tahminler daha başarılı çıkabilir.

## KAYNAKÇA

- Alduailij, M. A., Petri, I., Rana, O., Alduailij, M. A., & Aldawood, A. S. (2021). Forecasting peak energy demand for smart buildings. *The Journal of Supercomputing*, 77(6), 6356-6380. <https://doi.org/10.1007/s11227-020-03540-3>
- Ayoobi, N., Sharifrazi, D., Alizadehsani, R., Shoeibi, A., Gorriz, J. M., Moosaei, H., Khosravi, A., Nahavandi, S., Gholamzadeh Chofreh, A., Goni, F. A., Klemeš, J. J., & Mosavi, A. (2021). Time series forecasting of new cases and new deaths rate for COVID-19 using deep learning methods. *Results in Physics*, 27, 104495. <https://doi.org/10.1016/j.rinp.2021.104495>
- Bi, J.-W., Li, H., & Fan, Z.-P. (2021). Tourism demand forecasting with time series imaging: A deep learning model. *Annals of Tourism Research*, 90, 103255. <https://doi.org/10.1016/j.annals.2021.103255>
- Cheng, Q., Argon, N. T., Evans, C. S., Liu, Y., Platts-Mills, T. F., & Ziya, S. (2021). Forecasting emergency department hourly occupancy using time series analysis. *The American Journal of Emergency Medicine*, 48, 177-182. <https://doi.org/10.1016/j.ajem.2021.04.075>
- Di Piazza, A., Di Piazza, M. C., La Tona, G., & Luna, M. (2021). An artificial neural network-based forecasting model of energy-related time series for electrical grid management. *Mathematics and Computers in Simulation*, 184, 294-305.
- Dittmer, C., Krümpel, J., & Lemmer, A. (2021). Power demand forecasting for demand-driven energy production with biogas plants. *Renewable Energy*, 163, 1871-1877.
- Gijon, C., Toril, M., Luna-Ramírez, S., Mari-Altozano, M. L., & Ruiz-Avilés, J. M. (2021). Long-term data traffic forecasting for network dimensioning in LTE with short time series. *Electronics*, 10(10), 1151.
- Gülmez, B. (2021, Aralık). *Prediction of Retail Prices of Roasted Coffee by Time Series Analysis*. International Anatolian Congress on Coffee and Cocoa, Malatya, Turkey.
- Gülmez, B., & Kulluk, S. (2019). Social spider algorithm for training artificial neural networks. *International Journal of Business Analytics (IJBAN)*, 6(4), 32-49. <https://doi.org/10.4018/IJBAN.2019100103>
- Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and practice*. OTexts.
- Karakoyun, E. Ş. (2018). *Derin öğrenme ile zaman serilerinin gerçek zamanlı tahmini* [MasterThesis, Necmettin Erbakan Üniversitesi,

- Fen Bilimleri Enstitüsü]. <https://acikerisim.erbakan.edu.tr/xmlui/handle/20.500.12452/6412>
- Kim, Y., & Kim, S. (2021). Forecasting Charging Demand of Electric Vehicles Using Time-Series Models. *Energies*, 14(5), Art. 5. <https://doi.org/10.3390/en14051487>
- Piccolo, D. (1990). A Distance Measure for Classifying Arima Models. *Journal of Time Series Analysis*, 11(2), 153-164. <https://doi.org/10.1111/j.1467-9892.1990.tb00048.x>
- Rožanec, J. M., Fortuna, B., & Mladenčić, D. (2022). Reframing demand forecasting: A two-fold approach for lumpy and intermittent demand. *Sustainability*, 14(15), 9295.
- Şen, D. (2020). *Türkiye medikal turizmi üzerine bir tahmin çalışması*. <http://acikerisim.medipol.edu.tr/xmlui/handle/20.500.12511/7799>
- Talkhi, N., Akhavan Fatemi, N., Ataei, Z., & Jabbari Nooghabi, M. (2021). Modeling and forecasting number of confirmed and death caused COVID-19 in IRAN: A comparison of time series forecasting methods. *Biomedical Signal Processing and Control*, 66, 102494. <https://doi.org/10.1016/j.bspc.2021.102494>
- Valipour, M. (2015). Long-term runoff study using SARIMA and ARIMA models in the United States. *Meteorological Applications*, 22(3), 592-598. <https://doi.org/10.1002/met.1491>